Gestión de la información del proyecto

Proyecto Final PISA 2022 Colombia

Vanessa Acosta, Mateo Ramos y Brayan David Barreto · Consultoría Estadística, Universidad Santo Tomás · 2026-II · 6 de octubre de 2026

1. Por qué necesitamos gestionar la información

Somos tres personas trabajando ocho semanas con unas cuarenta fuentes, casi 6 GB de datos de la OCDE, decenas de decisiones metodológicas y un asistente de inteligencia artificial. Sin un sistema, los riesgos son concretos: cifras que nadie sabe de dónde salieron, dos versiones distintas del mismo documento, citas atribuidas a la página equivocada y datos de menores expuestos. Por eso trabajamos con **tres reglas**:

1. **Toda cifra tiene su script**: si un número va al documento, sabemos qué código y qué archivo lo producen.
2. **Toda afirmación tiene su fuente y su página**, con un estado de verificación (ver la sección 3).
3. **Toda decisión se registra antes de programarla**, con fecha, alternativas y razón.

Y una regla sobre la IA: **solo una persona del equipo marca algo como verificado**, cotejándolo contra el original.

2. Las herramientas y para qué sirve cada una

Herramienta	Para qué la usamos
Zotero 10 + Zotero Connector	Biblioteca de fuentes: cada artículo o libro con sus datos correctos (autores, año, DOI), su PDF y los subrayados **con su página**. Trabajamos en un **grupo compartido**, *Proyecto Final PISA*.
Better BibTeX (en Zotero)	Da a cada fuente una **clave de cita fija** (por ejemplo, `oecd2024pisa2022tr`), la misma en Zotero, en Obsidian y en el documento. De ahí sale `referencias.bib`.
Obsidian	El cuaderno del proyecto y **única fuente de verdad** (60 notas): objetivos, plan, decisiones, hipótesis, protocolo y **una nota por fuente** con lo que usamos, la página y su estado.
ZotLit (Obsidian y Zotero)	Conecta cada referencia de Zotero con su nota en Obsidian (36 ya conectadas) y trae los subrayados.
Dataview (Obsidian)	Tablas automáticas, por ejemplo la lista de fuentes con su estado de verificación.
R 4.4.1, RStudio, R Markdown	Leer PISA solo para Colombia, calcular y escribir el anteproyecto con citas automáticas.
Git + GitHub Desktop	Historial de cambios y sincronización de los tres en un **repositorio privado**. Datos y libros **no se suben**.
Claude (IA)	Revisa datos y fuentes y redacta borradores con las reglas de `CLAUDE.md`. Propone; el equipo verifica y decide.

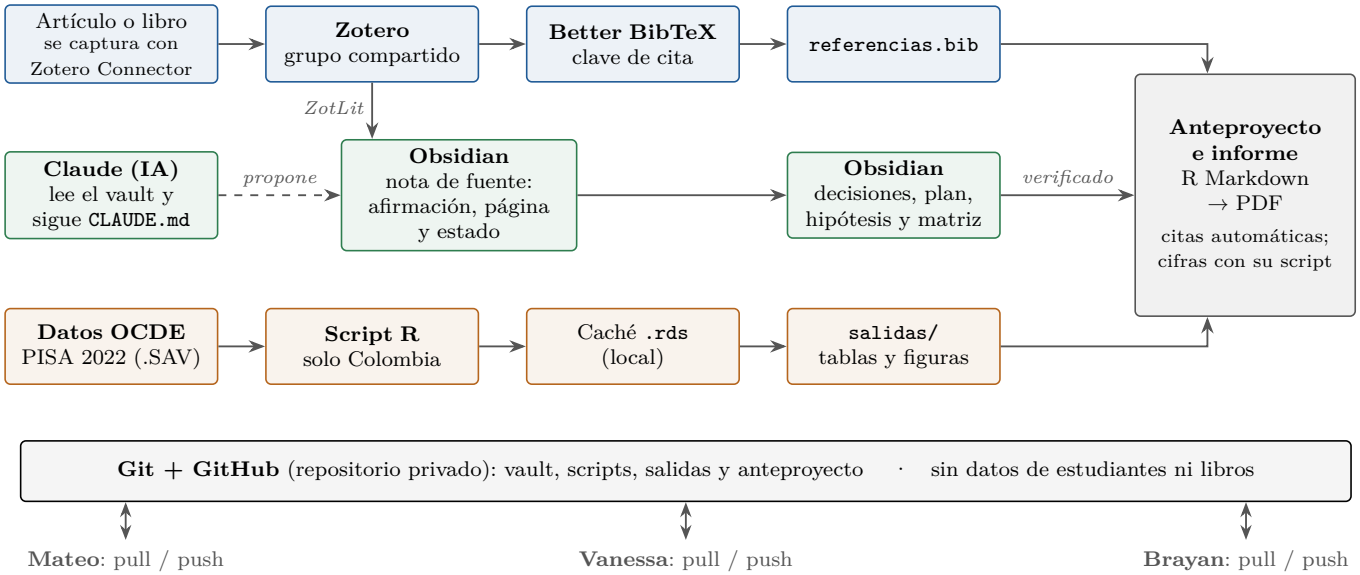
¿Y un sistema RAG? Lo evaluamos y lo descartamos para gestionar la información (decisión D-06): con unas cuarenta fuentes, un vault ordenado y un protocolo de verificación evitan más errores que un buscador automático. El RAG queda como posible producto del curso de Python, en la fase final.

3. El protocolo de verificación

Estado	Qué significa y si puede ir al documento
verificado	Lo comprobó una persona del equipo contra el original (página o script). **Puede ir.**
por verificar	Tiene origen, pero nadie lo ha cotejado; todo lo que aporta la IA empieza así. Solo va marcado [VERIFICAR].
sin origen	No tiene fuente ni script. **No va**: se busca el origen o se descarta.
descartado	Se comprobó que es falso o que no aplica. **No va**; se conserva tachado, con la razón.

El protocolo ya demostró su utilidad: **11 errores de la IA** fueron detectados, corregidos y registrados. Por ejemplo, números de capítulo citados sin verificar, una cifra tomada de un buscador sin fuente, y la afirmación de que un análisis "no se había hecho en PISA" cuando sí existía. La tarea pendiente del equipo es verificar las 43 fuentes contra sus PDF.

4. Cómo fluye la información entre las herramientas



Azul: fuentes · **Verde**: conocimiento y decisiones · **Naranja**: datos · **Negro**: control de versiones

El ciclo de una fuente. (1) Se captura en Zotero desde el navegador, directamente en el grupo. (2) Se lee y se subraya en el lector de Zotero: cada subrayado guarda su página. (3) ZotLit crea o actualiza su nota en Obsidian, donde anotamos qué afirmación usamos, en qué página y con qué estado. (4) En el documento se cita con su clave, por ejemplo `[@oecd2024pisa2022tr]`, y R Markdown arma la bibliografía en formato APA.

El ciclo de una cifra. Los datos de PISA nunca se suben: cada uno los descarga de la OCDE. Un script en R lee solo las filas de Colombia, guarda un caché local y produce tablas en `salidas/`. Ningún número entra al documento sin el script que lo produce.

5. Cómo trabajamos los tres

Momento	Qué hacemos	Para qué
Al empezar	En GitHub Desktop: *Fetch origin* → *Pull origin*	Traer el avance de los demás
Mientras trabajamos	Notas en Obsidian, fuentes en el grupo de Zotero, scripts y anteproyecto en RStudio	Zotero se sincroniza solo
Al terminar	*Commit* con un resumen corto → *Push origin*	Guardar y compartir el avance

- **Cada uno tiene su parte y otro la revisa** (reparto propuesto): Mateo, O1 y O2; Vanessa, O3; Brayan, O4 y O5. La verificación de las fuentes se reparte entre los tres, y en la sustentación cada uno expone una parte que no hizo.
- **Para no pisarnos**: *pull* antes de empezar, cada quien en sus notas y scripts, y nadie edita el mismo archivo que otro al mismo tiempo. Si GitHub Desktop muestra un conflicto, lo resolvemos juntos.
- **Las fuentes nuevas se agregan directamente en el grupo** de Zotero (no en *Mi biblioteca*), para que conserven su clave de cita.
- **Lo que nunca se sube**: datos de estudiantes (Ley 1581 de 2012) y libros con derechos de autor. El archivo `.gitignore` los excluye automáticamente.

6. Qué vamos a hacer: resumen del proyecto

Pregunta. ¿En qué medida el nivel socioeconómico (NSE), medido como variable latente que funciona igual en todos los grupos, explica el desempeño de los estudiantes colombianos en cada una de las cuatro competencias matemáticas de PISA 2022 (formular, emplear, interpretar y razonar), calificadas con un modelo de TRI propio? ¿Y cuánto de la brecha depende de cómo se califica?

Datos. PISA 2022 para Colombia: **7.804 estudiantes**, **232 ítems de matemáticas** que se pueden calibrar y **27 preguntas de posesiones del hogar** para medir el NSE.

Objetivo	Qué haremos	Curso
O1. Medir el NSE	Modelo de TRI y análisis factorial sobre las posesiones del hogar y la educación y ocupación de los padres; comparar una dimensión contra dos (económica y cultural)	TRI · SEM
O2. Verificar que se mide igual	Invarianza de medición por zona, sexo y sector del colegio	SEM · TRI
O3. Calificar por competencias	TRI multidimensional propio con las 4 competencias, validado contra los puntajes oficiales de la OCDE; revisar si algún ítem favorece a un grupo socioeconómico (DIF) y cómo cambia la brecha según se traten las preguntas omitidas	TRI
O4. Explicar el desempeño	Modelo de ecuaciones estructurales del NSE sobre cada competencia, con pesos muestrales y valores plausibles	SEM
O5. Poner los resultados a disposición	API en FastAPI y tablero con resultados agregados (nunca individuales)	Python

Semana	Fechas	Fase	Control al cerrar la fase
1	5–11 oct	Organización (casi cerrada) · limpieza y unión de los datos	—
2	12–18 oct	Reproducir las cifras publicadas por la OCDE para Colombia	Si no coinciden, no se avanza
3	19–25 oct	O1: medición del NSE	Ajuste aceptable o explicado
4	26 oct–1 nov	O2: invarianza	—
5	2–8 nov	O3: calificación por competencias y DIF	Ítems con datos suficientes
6	9–15 nov	O4: modelo estructural por competencia	—
7	16–22 nov	Robustez y búsqueda formal de novedad	Resultados congelados
8	23–29 nov	O5: API y tablero · informe y sustentación	—

Dónde estamos hoy.

- **Ya registrado:** 9 decisiones y 8 hipótesis. Las hipótesis se congelan con fecha **antes** de estimar cualquier modelo, para que los resultados no las acomoden.
- **Anteproyecto:** 36 referencias y 15 afirmaciones marcadas [VERIFICAR], pendientes de cotejar.
- **Siguiente paso:** congelar las hipótesis y empezar la limpieza de los datos.

Qué tiene de nuevo. Hay estudios del NSE con PISA y de ítems que favorecen a un grupo socioeconómico, pero no encontramos ninguno que combine, para Colombia, un NSE latente con invarianza probada, una calificación propia por competencias y la revisión de cómo la calificación de los ítems y de las omisiones cambia la brecha. Eso se confirmará con una búsqueda formal en la semana 7.

Origen de las cifras. Estudiantes, ítems y preguntas de posesiones: `Proyecto_PISA/datos/revision_pisa2022_col.R` (corrida del 5 de octubre de 2026). Notas, fuentes, decisiones, hipótesis y errores: conteo sobre `Vault_PISA2022` el 6 de octubre de 2026. Tamaño de los datos: archivos .SAV de la OCDE en `Proyecto_PISA/datos/`. Calendario y objetivos: notas 06 y 07 del vault.