Nivel socioeconómico latente y desempeño matemático por competencias en PISA 2022 (Colombia)

Informe final — Consultoría Estadística, Teoría de Respuesta al Ítem, Ecuaciones Estructurales y Python para APIs e IA

Vanessa Acosta, Mateo Ramos y Brayan David Barreto

Universidad Santo Tomás · 2026-II

Índice

1 Resumen **2**
Abstract . . . 2

2 Planteamiento del problema **3**

3 Objetivos e hipótesis **4**

4 Datos y diseño muestral **4**
4.1 Fuente y muestra analítica . . . 4
4.2 Validación del diseño (Puerta G1) . . . 5

5 Medición del NSE (O1, F3) **6**

6 Invarianza del NSE (O2, F4) **7**

7 Calificación por competencias (O3, F5) **8**
7.1 Una o cuatro dimensiones (H8) . . . 8
7.2 Puntajes propios por competencia . . . 9
7.3 DIF por NSE (H3) . . . 10
7.4 Omisiones (H4) . . . 10
7.5 Validez frente a la OCDE (H7) y concordancia de los ítems . . . 11

8 Modelo estructural (O4, F6) **11**

9 Robustez (F7) **13**

10 Hallazgos y discusión **15**

11 Limitaciones **16**

12 Productos: API y tablero (O5, F8) **17**

13 Conclusiones **17**

14 Declaración de uso de IA y reparto del trabajo **18**

15 Anexo: glosario de siglas, códigos e indicadores **19**
15.1 Códigos del proyecto 19
15.2 Siglas y términos estadísticos 20
15.3 Los 29 indicadores del NSE 20

Referencias **21**

Cómo se construyó este informe. Todas las cifras del texto y de las tablas se leen de `Proyecto_PISA/salidas/` al compilar; ninguna se escribió a mano. El equipo verificó todas las fuentes citadas (notas en `Vault_PISA2022/Literatura/`, 2026-11-10), con tres salvedades: de Goh et al. (2024) y Pohl et al. (2014) solo se cotejó el resumen, no el texto completo; de Köhler et al. (2015) y Mittal et al. (2022), el resumen dentro del PDF; y las referencias de software y de método (mirt, lavaan, Rubin y Wu) solo se cotejaron con sus datos bibliográficos, porque no se les atribuye ningún resultado. Los cortes de Chen (2007) se citan a través de Sokolov (2019) porque el equipo no consiguió el artículo original. Los párrafos marcados *(interpretación)* son lecturas de los resultados, no resultados. El diseño es transversal: se escribe «asociación» o «coeficiente», nunca «efecto causal» (plan, paso 9.1). El anexo final explica las siglas, los códigos del proyecto (O, H, F, G, D, K, S…) y los 29 indicadores del NSE. Los resultados están congelados con la etiqueta `resultados-v1` (Puerta G4, 2026-11-10); si se corrige un error en alguna salida, el texto cambia solo al volver a compilar.

1. Resumen

Problema. En Colombia la brecha socioeconómica en matemáticas se reporta con un índice de nivel socioeconómico (NSE) unidimensional y un puntaje global. Se pregunta cuánto se asocia el NSE con cada competencia matemática de PISA 2022 y si la brecha depende de cómo se mide el NSE y se califica la prueba.

Datos y métodos. Se analizan 6.886 estudiantes colombianos con NSE y al menos 10 ítems de matemáticas (87,5 % de la población ponderada). El NSE se mide como constructo latente con análisis factorial y Teoría de Respuesta al Ítem (TRI), y su invarianza se prueba por zona, sexo y sector. Las matemáticas se calibran con un modelo TRI de cuatro competencias; el funcionamiento diferencial de los ítems (DIF) y las omisiones se evalúan con hipótesis preregistradas. Se usan valores plausibles, pesos y réplicas BRR.

Resultados. El NSE tiene dos dimensiones (económica y libros en el hogar), con ajuste bajo los cortes usuales. Las competencias correlacionan entre 0,897 y 0,976, y el BIC prefiere una dimensión. Una desviación estándar del NSE económico se asocia con 24,2 a 29,4 puntos PISA más, algo más en *interpretar* (5,57 puntos sobre emplear; exploratorio). La pendiente del NSE es mayor en colegios privados. Solo 3 de 154 ítems tienen DIF por NSE, y tratar las omisiones rápidas como faltantes reduce la brecha apenas 0,007 a 0,008 desviaciones estándar.

Conclusión. La brecha no es un artefacto de la calificación, pero las competencias casi no se distinguen con los ítems que ve cada estudiante.

Palabras clave: nivel socioeconómico, teoría de respuesta al ítem, ecuaciones estructurales, invarianza de medición, PISA 2022.

Abstract

Problem. In Colombia, the socioeconomic gap in mathematics is reported with a one-dimensional socioeconomic status (SES) index and a single score. We ask how strongly SES is associated with each of the four PISA 2022 mathematics processes, and whether the gap depends on how SES is measured and the test is scored.

Data and methods. We analyze 6,886 Colombian PISA 2022 students with an SES index who saw at least 10 mathematics items (87.5 % of the weighted population). SES is measured as a latent construct with factor analysis and item response theory (IRT), and its invariance is tested by area, sex and school sector. Mathematics is calibrated with a four-dimensional IRT model; differential item functioning (DIF) and omissions are evaluated against preregistered hypotheses. Estimates use plausible values, weights and BRR replicates.

Results. SES has two dimensions (economic and books at home), with fit below the usual cutoffs. The processes correlate between 0.897 and 0.976, and the BIC favors one dimension. One standard deviation of economic SES is associated with 24.2 to 29.4 more PISA points, slightly more in *interpreting* (5.57 points above employing; exploratory). The SES slope is steeper in private schools. Only 3 of 154 items show DIF by SES, and treating rapid omissions as missing reduces the gap by only 0.007 to 0.008 standard deviations.

Conclusion. The socioeconomic gap is not an artifact of scoring, but the processes can hardly be separated with the items each student sees.

Keywords: socioeconomic status, item response theory, structural equation modeling, measurement invariance, PISA 2022.

2. Planteamiento del problema

Colombia participa en PISA, el programa de la OCDE que evalúa a estudiantes de 15 años escolarizados. En el ciclo 2022, cuyo dominio principal fue matemáticas, la muestra de Colombia fue de 7.804 estudiantes (`salidas/conteos_muestra.csv`). El estatus socioeconómico explica el 16,2 % de la variación del desempeño en matemáticas y la diferencia entre el cuartil más alto y el más bajo del índice oficial es de 78,6 puntos (cálculo propio, `02_validacion_ocde.R`, que reproduce las cifras publicadas: 16 % y 79 puntos en la nota de país de Colombia de la OCDE, p. 5). El informe nacional también reporta el 16 % (Icfes, 2024, p. 46).

Que el NSE se asocie con el desempeño no es lo que el proyecto busca redescubrir. El problema está en dos decisiones de medición que suelen tomarse sin discusión y que determinan la magnitud de la brecha que se reporta (anteproyecto, sección 1):

1. **Cómo se mide el NSE.** El índice oficial de PISA (ESCS) combina ocupación y educación de los padres y posesiones del hogar; la OCDE evalúa su comparabilidad entre países y grupos de idioma (OECD, 2024), pero no dentro de un país, entre zonas, sectores o sexos. La propia OCDE reconoce que su índice de posesiones se escala como una medida unidimensional (Avvisati & Wuyts, 2024, pp. 11, 48). En Colombia, el INSE del Icfes también asume una sola dimensión (Instituto Colombiano para la Evaluación de la Educación (ICFES), 2019), mientras que la literatura internacional distingue al menos una dimensión económica y otra cultural (Eriksson et al., 2021; Hernández Padilla & González Montesinos, 2011).
2. **Cómo se califica el desempeño.** El seguimiento público de las brechas se hace sobre puntajes agregados (Laboratorio de Economía de la Educación (LEE), Pontificia Universidad Javeriana, 2024). PISA 2022 define cuatro procesos matemáticos —formular, emplear, interpretar y razonar—, pero el informe nacional los reporta solo como promedios del país, sin cruzarlos con el NSE (Icfes, 2024). Además, PISA califica como incorrectas las respuestas omitidas, y el desenganche en la prueba puede variar con el NSE (Rios & Soland, 2022).

En este informe llamamos **competencias** a esos cuatro procesos.

Pregunta de investigación (`Vault_PISA2022/06 Objetivos PISA 2022.md`): ¿en qué medida el NSE, modelado como constructo latente cuya medición es igual entre grupos, explica el desempeño de los estudiantes colombianos en cada una de las cuatro competencias matemáticas de PISA 2022, y cuánto de la brecha observada depende de cómo se califica el desempeño?

Antecedentes y vacío (anteproyecto, sección 2). Los estudios colombianos relacionan puntajes observados con covariables socioeconómicas sin modelar el error de medición del NSE (Collazos Valenzuela et al., 2021;

Rodriguez-Gómez et al., 2024). El único antecedente encontrado que prueba invarianza del NSE entre grupos de estudiantes dentro de un país lo hace por origen inmigrante en Noruega y Suecia (Mittal et al., 2022). El DIF por NSE en matemáticas está documentado en México (García-Medina et al., 2016) y, con PISA 2022, en Corea con dos subpruebas (Goh et al., 2024), pero no en Colombia ni por competencia. Y ningún estudio revisado cuantifica cuánto cambia la brecha socioeconómica de Colombia según cómo se califiquen las omisiones (Köhler et al., 2015; Pohl et al., 2014).

3. Objetivos e hipótesis

Objetivo general. Determinar en qué medida el NSE, medido como constructo latente con invarianza verificada entre grupos, explica el desempeño de los estudiantes colombianos en las cuatro competencias matemáticas de PISA 2022, y en qué medida la brecha socioeconómica depende del funcionamiento de los ítems y del tratamiento de las omisiones.

Objetivos específicos. O1, medir el NSE; O2, verificar su invarianza por zona, sexo y sector; O3, calificar por competencias y verificar la equidad de la calificación (DIF y omisiones); O4, explicar el desempeño por competencia con un modelo estructural; O5, poner los resultados a disposición en una API y un tablero.

Las hipótesis se congelaron el 2026-10-12 (commit `f53054d`; nota *09 Hipótesis preregistradas* del vault). Las desviaciones posteriores están en el registro de decisiones y se declaran donde aplican. Las dos principales son:

- **D-32:** al rechazarse H8, la F6 (O4, H5 y H6) se estima con los valores plausibles (VP) de la OCDE como análisis principal y los puntajes propios pasan a robustez; el preregistro decía lo contrario. Por la misma decisión, **H5 se presenta como exploratoria**: salió de una revisión de los mismos datos.
- **D-22:** definiciones operativas de H2 a H7 fijadas antes de estimar; las hipótesis no cambiaron.

Cuadro 1: Hipótesis preregistradas y su estado (leído de salidas/).

Hipótesis	Objetivo	Enunciado	Resultado
H1	O1	NSE de dos dimensiones	se acepta
H2	O2	Sin invarianza escalar rural-urbana	se rechaza
H3	O3	DIF por NSE en interpretar y formular	se acepta solo la primera parte
H4	O3	Tratar omisiones rápidas como faltantes reduce la brecha	se rechaza
H5	O4	Asociación del NSE mayor en interpretar que en emplear (exploratoria)	se cumple la regla (exploratoria, D-32)
H6	O4	La asociación del NSE difiere entre zonas o sectores	se acepta
H7	O3	Puntajes propios válidos frente a la OCDE	se rechaza
H8	O3	Matemáticas multidimensional	se rechaza (D-27)

4. Datos y diseño muestral

4.1. Fuente y muestra analítica

La única fuente es la base pública de PISA 2022 de la OCDE, consultada el 4 de octubre de 2026 (OECD, 2023), bloque de Colombia (D-01): cuestionario del estudiante, archivo de ítems cognitivos (respuesta califi-

cada y tiempo por ítem) y archivo de colegios. La muestra analítica son los estudiantes con ESCS y al menos 10 ítems de matemáticas **vistos**, es decir, respondidos u omitidos (D-14).

Cuadro 2: Conteos de la muestra (01c_muestra_analitica.R).

Conjunto	n	% ponderado
Total Colombia	7.804	100,00
Con ESCS	7.459	94,89
>= 10 ítems con tiempo válido (revisión 29/09, control)	7.222	92,39
>= 10 ítems vistos (D-14: respondido u omitido)	7.198	92,09
Con ESCS y >= 10 con tiempo válido (control)	6.910	87,80
Muestra analítica: con ESCS y >= 10 vistos (D-14)	6.886	87,51
Motivo: incluido	6.886	87,51
Motivo: excluido: sin ESCS	312	4,58
Motivo: excluido: menos de 10 vistos	573	7,39
Motivo: excluido: sin ESCS y menos de 10 vistos	33	0,52

Cuadro 3: Media de matemáticas de incluidos y excluidos (10 VP, BRR; 01c_muestra_analitica.R).

Grupo	n	Media	EE	Dif. con incluidos	EE dif.	z
incluidos	6.886	384,5	3,1			
excluidos (todos)	918	369,9	3,8	-14,6	3,0	-4,86
excluido: sin ESCS	312	359,8	6,0	-24,8	5,7	-4,33
excluido: menos de 10 vistos	573	376,9	4,0	-7,6	3,3	-2,31
excluido: sin ESCS y menos de 10 vistos	33	359,3	12,2	-25,2	11,9	-2,12

La exclusión **no es aleatoria**. Los 918 excluidos rinden 14,6 puntos menos que los incluidos (EE 3,0; z = -4,86), y la diferencia es mayor entre quienes no tienen ESCS (24,8 puntos). Los análisis describen, por tanto, a la población analítica (87,5 % de la ponderada) y no a todos los estudiantes. Para medir cuánto importa esto, la fase de robustez repite los resultados principales con un ajuste de no respuesta por colegio (D-38, sección 9).

4.2. Validación del diseño (Puerta G1)

Antes de cualquier modelo se reprodujeron tres cifras publicadas con los 10 valores plausibles, el peso final y las 80 réplicas BRR con Fay 0,5 [OECD (2024), p. 198, fórmula 10.9; reglas de Rubin, p. 226]. Las tres coinciden con lo publicado dentro del redondeo, lo que confirma que el procesamiento de pesos, réplicas y valores plausibles es correcto.

Cuadro 4: Puerta G1: cifras propias frente a las publicadas (02_validacion_ocde.R).

Paso	Cifra	Estimación	EE	Publicado	Cumple	Fuente
2.1	Media de matemáticas	382,70	3,03	382,7	sí	Technical Report 2022, Annex Table 14.A.12, p. 301
2.2	Brecha Q4 - Q1 de ESCS (puntos)	78,56	5,74	79,0	sí	Ficha OCDE Colombia, p. 5
2.3	Varianza explicada por ESCS (%)	16,16	2,09	16,0	sí	Ficha OCDE Colombia, p. 5

5. Medición del NSE (O1, F3)

Indicadores y estrategia. Se usaron 29 indicadores ordinales: posesiones del hogar (ST250 a ST256, incluidos 8 tipos de libros), educación de los padres (`HISCED`) y ocupación (`HISEI`) (D-16). Cuando el cuestionario salta una pregunta por una respuesta anterior (por ejemplo, los tipos de libros a quien no tiene libros), el salto se codificó como 0 y no como faltante (D-20). La muestra se dividió en dos mitades por colegio (3.445 y 3.441 estudiantes; `salidas/nse_mitades.csv`): en la de exploración se hizo un análisis factorial exploratorio (AFE) y en la de confirmación un análisis factorial confirmatorio (AFC) con WLSMV en `lavaan` (Rosseel, 2012). Luego se calibraron los ítems con TRI (2PL y crédito parcial generalizado) en `mirt` (Chalmers, 2012) sobre la muestra analítica completa.

Resultado (H1). El modelo de dos factores mejora claramente al de uno: el CFI *scaled* sube 0,107 y la prueba de diferencia lo confirma ($\Delta\chi^2$ = 1.220,5 con 1 gl). Los dos factores correlacionan 0,559: están relacionados, pero no son lo mismo. **H1 se acepta** (`salidas/nse_h1_afc.csv`).

Modelo elegido (Puerta G2, D-24). Pasó a las fases siguientes la estructura de dos dimensiones del AFE: un factor **económico** (19 indicadores: bienes, educación y ocupación de los padres) y un factor de **libros** (10 indicadores). En la mitad de confirmación ajusta mejor que la estructura teórica de D-16 (CFI *scaled* 0,943 frente a 0,921; SRMR 0,071 frente a 0,087).

Cuadro 5: AFC en la mitad de confirmación (03_nse_afc.R). H1 compara M1 con M2; la G2 eligió M2-AFE (D-24).

Modelo	CFI scaled	CFI robust	RMSEA scaled	RMSEA robust	SRMR	r factores
M1	0,814	0,514	0,108	0,160	0,136	
M2	0,921	0,731	0,071	0,119	0,087	0,559
M2_AFE	0,943	0,753	0,060	0,114	0,071	0,523

Cuadro 6: Validez: correlación ponderada con los índices oficiales (03_nse_tri.R).

Puntuación	r HOMEPOS	r ESCS
eap_1D	0,907	0,738
eap_D16_ECO	0,955	0,771
eap_D16_CUL	0,650	0,513
eap_AFE_ECO	0,962	0,809
eap_AFE_CUL	0,618	0,473

Cuadro 7: Sensibilidad S1 (D-35): con los saltos de D-20 como 0 o como faltante (03_nse_sens_d20.R).

Medida	Saltos = 0 (D-20)	Saltos = faltante (S1)
correlación entre factores	0.483	0.569
información máxima, libros (theta del máximo)	33.1 (1.4)	13.2 (1.6)
rango con información >= 4, libros	-1.5 a 2.6	-0.9 a 2.9
información máxima, económico	10.6	10.1
rango con información >= 4, económico	-2.2 a 2.9	-2.2 a 2.9
confiabilidad empírica, económico	0.898	0.894
confiabilidad empírica, libros	0.902	0.813
r ponderada con HOMEPOS, económico	0.962	0.969
r ponderada con ESCS, económico	0.809	0.821
r ponderada con HOMEPOS, libros	0.618	0.748
r ponderada con ESCS, libros	0.473	0.581

Cuadro 7: Sensibilidad S1 (D-35): con los saltos de D-20 como 0 o como faltante (03_nse_sens_d20.R). (continúa)

Medida	Saltos = 0 (D-20)	Saltos = faltante (S1)
Q3 ST255-ST256: mínimo / máximo / pares con |Q3| > 0,2	-0.266 / -0.094 / 5	-0.217 / -0.058 / 3
r ponderada entre las EAP D-20 y S1, económico	—	0.995
r ponderada entre las EAP D-20 y S1, libros	—	0.923
r ponderada entre las EAP D-20 y S1, libros, solo quienes no tienen libros	—	0.983
estudiantes con los saltos como faltantes (libros / dispositivos)	0 / 0	1002 / 182
iteraciones del EM	45	33

Validez y precisión. El factor económico correlaciona 0,962 con el índice oficial de posesiones (HOMEPOS) y 0,809 con el ESCS, y su confiabilidad empírica es 0,898 (`salidas/nse_confiabilidad_tri.csv`). *(Interpretación del equipo, D-24:)* como junta bienes, educación y ocupación, en la práctica el factor «económico» es un NSE general, muy parecido a HOMEPOS; el segundo factor es el de libros en el hogar.

Limitaciones que hay que declarar.

- El ajuste no llega a los cortes usuales en las versiones *robust*: CFI *robust* 0,753 y RMSEA *robust* 0,114 en el modelo elegido (D-18, D-24). Las fuentes del desajuste son la educación y la ocupación de los padres, la separación entre lo digital y la vivienda, y algunos ítems con cargas bajas.
- La sensibilidad S1 (D-35) muestra que los ceros de D-20 **inflan la precisión del factor libros**: con los saltos como faltantes, su confiabilidad baja de 0,902 a 0,813. El factor económico, que es el que deciden H5, H6 y los cuartiles de H3 y H4, casi no cambia (0,898 frente a 0,894).

6. Invarianza del NSE (O2, F4)

Método. Se probó si el modelo del NSE mide lo mismo en cada grupo con la secuencia configural → umbrales → cargas → interceptos, con la identificación de Wu & Estabrook (2016) y los cortes de ΔCFI (0,01) y ΔRMSEA (0,015) de Chen (2007), citado en Sokolov (2019, p. 8), en sus versiones *scaled*, porque `lavaan` no calcula las *robust* con restricciones de igualdad (D-25). Cada variable de grupo se analizó por separado en la muestra analítica completa. H2 se decide con el contraste rural frente a urbana.

Cuadro 8: Secuencia de invarianza (04_invarianza.R, D-25 y D-28).

Análisis	Paso	CFI	RMSEA	dCFI	dRMSEA	Se sostiene	Dchi2	gl	p
zona	configural	0,9445	0,0576						
zona	umbrales	0,9436	0,0566	-0,0009	-0,0010	sí	140,8	58	7,84e-09
zona	cargas	0,9488	0,0528	0,0052	-0,0038	sí	168,8	54	9,50e-14
zona	interceptos	0,9455	0,0535	-0,0033	0,0007	sí	380,7	42	3,77e-56
H2_rural_urbana	configural	0,9418	0,0587						
H2_rural_urbana	umbrales	0,9410	0,0579	-0,0008	-0,0008	sí	92,9	29	1,28e-08
H2_rural_urbana	cargas	0,9457	0,0546	0,0047	-0,0033	sí	76,4	27	1,29e-06
H2_rural_urbana	interceptos	0,9430	0,0553	-0,0027	0,0007	sí	273,4	21	8,09e-46
sexo	configural	0,9410	0,0597						
sexo	umbrales	0,9403	0,0590	-0,0007	-0,0007	sí	33,0	29	2,78e-01
sexo	cargas	0,9462	0,0550	0,0059	-0,0040	sí	33,5	27	1,80e-01
sexo	interceptos	0,9441	0,0554	-0,0021	0,0004	sí	100,9	21	2,04e-12
sector	configural	0,9335	0,0564						
sector	umbrales	0,9324	0,0559	-0,0011	-0,0005	sí	163,3	29	1,14e-20
sector	cargas	0,9364	0,0533	0,0040	-0,0026	sí	260,5	27	4,82e-40
sector	interceptos	0,9298	0,0552	-0,0066	0,0019	sí	342,5	21	6,64e-60

Cuadro 9: Diferencias de medias latentes del NSE con error BRR (04_medias_brr.R, D-34). Unidades: DE del grupo de referencia.

Análisis	Factor	Grupo	Referencia	Diferencia	EE BRR	IC inf	IC sup
zona	ECO	Pueblo	Urbana	-0,630	0,108	-0,841	-0,419
zona	CUL	Pueblo	Urbana	-0,194	0,077	-0,344	-0,044
zona	ECO	Rural	Urbana	-0,949	0,142	-1,228	-0,670
zona	CUL	Rural	Urbana	-0,173	0,088	-0,346	0,000
H2_rural_urbana	ECO	Rural	Urbana	-0,950	0,142	-1,230	-0,671
H2_rural_urbana	CUL	Rural	Urbana	-0,173	0,088	-0,346	0,000
sexo	ECO	Hombre	Mujer	0,052	0,033	-0,014	0,117
sexo	CUL	Hombre	Mujer	-0,123	0,037	-0,195	-0,051
sector	ECO	Privado	Público	1,433	0,161	1,118	1,748
sector	CUL	Privado	Público	0,604	0,103	0,402	0,806

Resultado (H2). En el contraste rural–urbana, el paso escalar no empeora el ajuste (ΔCFI -0,0027, ΔRMSEA 0,0007), así que **H2 se rechaza** por su regla (`salidas/inv_h2.csv`). Ningún paso de ningún grupo supera los cortes preregistrados.

Cómo se redacta (D-35). Con el criterio preregistrado no se detectó no invarianza de magnitud relevante, pero **eso no demuestra la invarianza**:

- la prueba de diferencia χ^2 escalada la rechaza en 10 de 12 pasos (D-28);
- el CFI *scaled* **mejora** al restringir las cargas (de 0,004 a 0,006), así que no se comporta como una medida de ajuste;
- el ajuste de partida es pobre en las versiones *robust* (`salidas/invarianza_por_grupo.csv`).

DIF de las posesiones. Con TRI multigrupo (sin pesos en la prueba, D-26) y magnitud por ΔR^2 de Nagelkerke 0,035, solo un indicador tiene DIF: motos (`ST251Q02JA`) por zona, y también por sector con el emparejamiento multigrupo de la sensibilidad S2 (zona, $\Delta R^2 = 0{,}0435$; sector, $\Delta R^2 = 0{,}0350$; `salidas/nse_dif_sens_emparejamiento.csv`). Es un ítem poco informativo que se mantuvo en el modelo (D-24).

Diferencias de medias latentes. Con la invarianza que se sostiene por el criterio preregistrado, los estudiantes rurales tienen un NSE económico 0,95 DE menor que los urbanos, y los de colegios privados uno 1,43 DE mayor que los de públicos. Los errores BRR son entre 1,16 y 3,66 veces los de `lavaan`, sobre todo en zona y sector, que se agrupan por colegio (D-34).

7. Calificación por competencias (O3, F5)

7.1. Una o cuatro dimensiones (H8)

El diseño adaptativo hace que cada estudiante vea una mediana de 29 de los 232 ítems calibrados (11,7 % de las celdas con dato), y entre 5 y 9 por competencia (`salidas/mat_matriz_resumen.csv`). Con esos datos se compararon un modelo TRI de una dimensión y uno de cuatro competencias en el que cada ítem carga solo en la suya.

Cuadro 10: H8: modelos de 1 y 4 dimensiones (05_tri_competencias.R).

Modelo	Convergió	logLik	Parámetros	AIC	BIC	r min	r max
1D	sí	-99.810,2	526	200.672,4	204.268,8		
4D	sí	-99.797,3	532	200.658,6	204.296,1	0,897	0,976

El modelo de cuatro dimensiones solo agrega las 6 correlaciones entre competencias, y estas van de 0,897 a 0,976. El BIC es menor con una dimensión (204.268,8 frente a 204.296,1), así que **H8 se rechaza** (D-27). Un modelo bifactor exploratorio, con criterios de viabilidad fijados antes de estimarlo (D-29), **no fue viable**: no convergió en 2.000 ciclos y no se pudo calcular ningún error estándar (`salidas/mat_bifactor_viabilidad.csv`). Por eso no se interpreta el aporte propio de cada competencia.

Análisis confirmatorio de los ítems por competencia (exploratorio, D-48). Por sugerencia del curso de Ecuaciones Estructurales se revisó si cada ítem representa su competencia. Se decidió después de conocer H8 y así se declara. Un análisis factorial confirmatorio con `lavaan` no se puede estimar: con la prueba adaptativa, el 21,3 % de los pares de ítems nunca lo respondió el mismo estudiante y el 45,9 % lo respondieron menos de 50 (`salidas/mat_pares_cobertura.csv`), así que sus correlaciones policóricas no existen o son muy inestables. El modelo de cuatro competencias ya es ese análisis, con información completa: cada ítem carga en su competencia, pero 56 de 232 ítems tienen carga menor que 0,30 (todos dicotómicos), y las competencias correlacionan entre 0,897 y 0,976 (`salidas/mat_afc_resumen.csv`, `mat_afc_cargas.csv` y `mat_afc_phi.csv`). No cambia ninguna hipótesis. *(Interpretación:)* es coherente con los ítems muy difíciles y poco discriminantes en Colombia que encontró el enlace con los parámetros internacionales (D-43).

Cuadro 11: Cargas de los ítems en su competencia, modelo de 4 competencias (05_afc_competencias.R, D-48).

Competencia	Items	Carga mediana	Carga mínima	Carga máxima	Carga < 0,30	%
emplear	75	0,477	-0,207	0,912	22	29,3
formular	47	0,501	-0,065	0,928	17	36,2
interpretar	57	0,530	0,016	0,919	6	10,5
razonar	53	0,630	-0,011	0,974	11	20,8
total	232	0,522	-0,207	0,974	56	24,1

(Consecuencia para el análisis, D-32.) Con tan pocos ítems por competencia y correlaciones tan altas, un puntaje propio de cada competencia depende mucho de las demás y del modelo de condicionamiento. Por eso el modelo estructural (O4) usa como principal los VP de proceso de la OCDE, y los puntajes propios quedan para H4, H7 y la robustez.

7.2. Puntajes propios por competencia

Los puntajes propios se generaron con una regresión latente sobre el modelo de cuatro competencias (D-39): un algoritmo EM propio con integración de Gauss-Hermite adaptativa centrada en la moda de cada estudiante (E1, D-33), con las covariables de la F6 y las interacciones NSE × zona y NSE × sector (D-37). La integración se validó contra una malla fina: la diferencia máxima de la EAP fue de 0,0016 DE con covariables (`salidas/mat_rl_validacion.csv`), frente a 0,21–0,25 DE con la integración inicial (`salidas/mat_posterior_V1.csv`, D-27). Las cuatro competencias cumplen los tres criterios de validación.

Cuadro 12: Confiabilidad empírica de los puntajes propios (05_puntajes_rl.R).

Competencia	Con covariables	Sin covariables	EE posterior mediano
emplear	0,817	0,793	0,404
formular	0,760	0,741	0,469
interpretar	0,790	0,768	0,442
razonar	0,796	0,766	0,428

La confiabilidad con covariables va de 0,760 a 0,817, y la regresión latente explica entre 0,360 y 0,386 de la varianza de cada competencia (`salidas/mat_rl_ajuste.csv`).

7.3. DIF por NSE (H3)

Método (D-36, D-40). Se calibraron los ítems en una dimensión con dos grupos —cuartil bajo (Q1) y alto (Q4) del NSE económico— con medias y varianzas libres, y se probaron los ítems con al menos 100 respuestas en cada cuartil y todas sus categorías en los dos grupos. Un ítem tiene DIF si su prueba TRI es significativa después de Benjamini-Hochberg **y** su magnitud no es despreciable: categoría B o C del ETS por Mantel-Haenszel en los dicotómicos, o ΔR^2 0,035 en los de crédito parcial.

Cuadro 13: DIF por NSE dentro de cada competencia (05_dif_matematicas.R, D-36 y D-40).

Competencia	Elegibles	Signif. BH	No despreciables	Con DIF	% con DIF
emplear	57	6	12	3	5,3
formular	29	0	4	0	0,0
interpretar	37	3	4	0	0,0
razonar	31	1	2	0	0,0

Cuadro 14: Ítems con DIF por NSE (parámetros de ítems, sin datos de estudiantes).

Ítem	Competencia	Delta MH	ETS	Favorece
CMA113Q03S	emplear	1,13	B	Q1 (NSE bajo)
CMA131Q02S	emplear	-1,33	B	Q4 (NSE alto)
CMA135Q04S	emplear	2,07	C	Q1 (NSE bajo)

Resultado. 3 de 154 ítems tienen DIF, todos en *emplear*; 2 de ellos favorecen al cuartil bajo. **H3 se acepta solo en su primera parte** (hay ítems con DIF); la segunda se rechaza, porque interpretar y formular no concentran más DIF que emplear (prueba de Fisher de una cola, `salidas/mat_h3.csv`). *(Interpretación:)* con efectos en los dos sentidos, el DIF es escaso y no apunta a un sesgo sistemático contra el cuartil bajo. `CMA131Q02S` tiene discriminación casi nula en Colombia (`salidas/mat_p3_baja_discriminacion.csv`), así que su DIF puede reflejar un mal funcionamiento general del ítem. **Salvedad:** dos ítems (`DM446Q02C` y `CM00GQ01S`) tienen ΔMH infinito; su categoría A no es una magnitud observada, aunque no cambian H3 porque su prueba TRI no es significativa (D-40).

7.4. Omisiones (H4)

Se recalificaron las respuestas omitidas en menos tiempo que el umbral NT10 («omisiones rápidas»: 4.852 de 12.490 omisiones) como faltantes, con el mismo modelo y los mismos números aleatorios (D-41), y se comparó la brecha Q4 − Q1 en desviaciones estándar.

Cuadro 15: Brecha Q4 - Q1 en DE: (a) omisión = incorrecta; (b) omisión rápida = faltante; (c) toda omisión = faltante (05_h4_h7.R, D-41).

Competencia	Brecha (a)	Brecha (b)	Reducción (b)	EE reducción	p Holm	Reducción (c)
emplear	1,1831	1,1756	0,0075	0,0040	0,237	0,0184
formular	1,1758	1,1685	0,0073	0,0039	0,237	0,0153
interpretar	1,2294	1,2219	0,0075	0,0040	0,237	0,0200
razonar	1,1669	1,1595	0,0074	0,0040	0,237	0,0179

La brecha es de 1,17 a 1,23 DE. Tratar las omisiones rápidas como faltantes la reduce solo 0,0073 a 0,0075

DE, lejos del umbral de 0,05 y sin significancia (p con Holm = 0,237). Incluso tratando **toda** omisión como faltante, la reducción es de 0,015 a 0,020 DE. **H4 se rechaza**: es un resultado nulo bien medido.

7.5. Validez frente a la OCDE (H7) y concordancia de los ítems

Cuadro 16: Correlación de los VP propios (filas) con los de la OCDE (columnas) (05_h4_h7.R).

propio	emplear (MPEM)	formular (MPFS)	interpretar (MPIN)	razonar (MPRE)
emplear	0,752	0,669	0,748	0,685
formular	0,718	0,653	0,714	0,659
interpretar	0,734	0,651	0,743	0,670
razonar	0,740	0,663	0,737	0,680

Cuadro 17: Concordancia de las dificultades con las internacionales (P3; 05_p3_robusto.R, D-43, posterior a ver resultados).

Competencia	Items	Spearman (todos)	Ítems a >= 0,3	Pearson (a >= 0,3)	Pendiente A	Intercepto B	RMSD
razonar	35	0,703	30	0,776	0,416	-0,682	0,543
formular	35	0,877	27	0,794	0,548	-0,978	0,373
interpretar	38	0,932	36	0,976	0,565	-0,922	0,211
emplear	62	0,932	52	0,888	0,440	-0,934	0,269

La correlación de cada puntaje propio con la misma competencia de la OCDE va de 0,653 a 0,752: ninguna llega a 0,80, y en formular y razonar la correlación es mayor con el VP de *emplear* de la OCDE que con el propio. **H7 se rechaza** (`salidas/mat_h7.csv`). *(Interpretación, D-41:)* es coherente con que las competencias casi no se distinguen (H8); además, con confiabilidades de 0,76 a 0,82 en los puntajes propios, el umbral de 0,80 era difícil de alcanzar aun si los constructos coincidieran.

El orden de dificultad de los ítems en Colombia sí concuerda con el internacional (Spearman de 0,70 a 0,93; razonar es la que menos). Este análisis (P3) se rehízo después de ver que el enlace fijado en D-41 quedaba dominado por ítems con discriminación casi nula, un error de diseño declarado en D-41 y D-43.

8. Modelo estructural (O4, F6)

Método (D-42). Análisis principal en dos pasos: para cada competencia y cada uno de los 10 VP de la OCDE, regresión ponderada sobre las puntuaciones del NSE económico y de libros (G2), con sexo y grado como covariables; errores con las 80 réplicas BRR y reglas de Rubin (Rubin, 1987) (810 ajustes por modelo). Los coeficientes se reportan en puntos PISA por unidad de la puntuación del NSE y por desviación estándar (DE). Como robustez se estimó un SEM con el NSE latente (WLSMV, 29 indicadores) y se repitió todo con los puntajes propios (D-44).

Cuadro 18: Coeficientes del NSE por competencia, en puntos PISA (06_sem_competencias.R, 10 VP de la OCDE, BRR + Rubin).

Competencia	NSE	Coef	EE	IC inf	IC sup	Por DE	R2
emplear	económico	25,47	1,89	21,75	29,18	24,15	0,298
emplear	libros	7,34	1,85	3,71	10,96	6,96	0,298
formular	económico	26,19	3,13	20,05	32,33	24,84	0,244
formular	libros	12,76	2,51	7,83	17,68	12,10	0,244
interpretar	económico	31,04	2,34	26,44	35,63	29,43	0,310
interpretar	libros	8,50	1,75	5,08	11,92	8,06	0,310
razonar	económico	25,60	2,84	20,03	31,17	24,27	0,238
razonar	libros	9,89	2,09	5,80	13,97	9,38	0,238

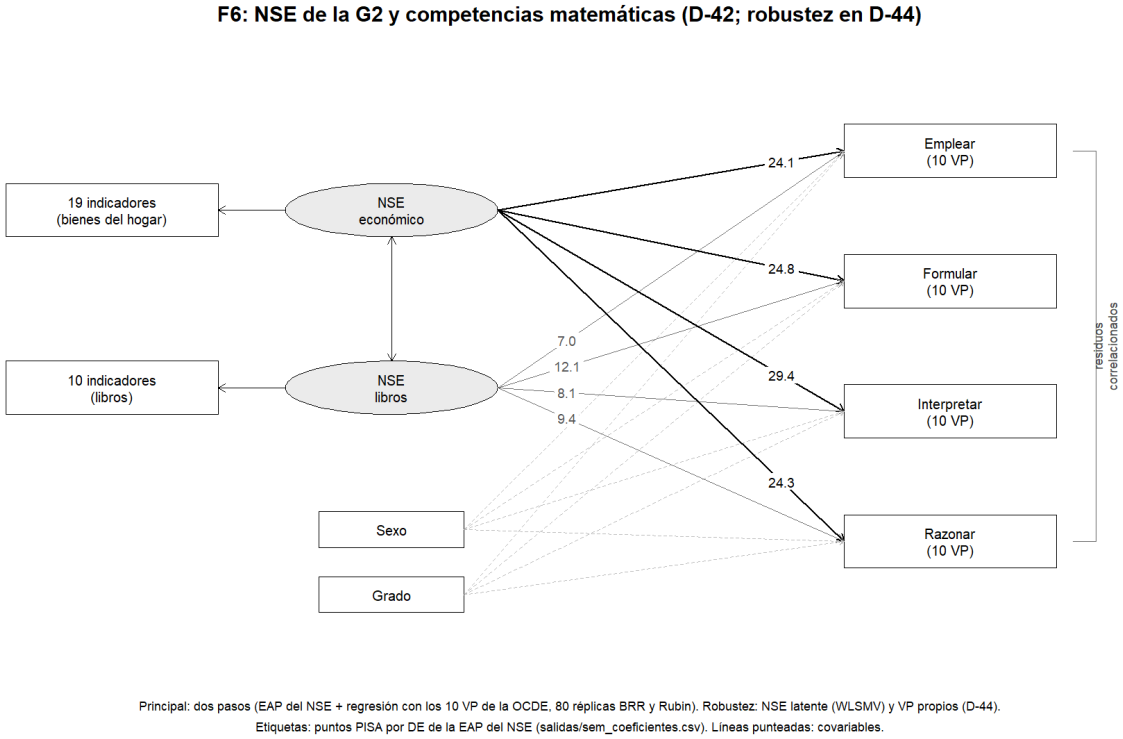


Figura 1: Modelo de la F6 y coeficientes del NSE en puntos PISA por DE (diagrama de la carpeta de salidas, D-44).

Asociación con cada competencia. El NSE económico se asocia positivamente con las cuatro competencias: entre 24,2 y 29,4 puntos por DE, con el valor más alto en *interpretar*. El factor de libros agrega entre 7,0 y 12,1 puntos por DE. El modelo explica entre 0,238 y 0,310 de la varianza.

Igualdad entre competencias. La prueba de Wald de que el coeficiente del NSE económico es igual en las cuatro competencias se rechaza ($\chi^2 = 11{,}32$ con 3 gl, p = 0,010).

H5 (exploratoria). La diferencia interpretar − emplear es de 5,57 puntos (EE 1,70; IC 95 % 2,24 a 8,89; p = 0,001) en la muestra completa y de 6,33 puntos (p < 0,001) en la mitad de confirmación. Cumple la regla preregistrada en las dos, pero se presenta como **exploratoria** (D-32).

H6 (zona y sector). La interacción NSE × sector es significativa ($\chi^2 = 15{,}58$ con 4 gl; p = 0,007 con Holm): en los colegios privados, la pendiente del NSE es entre 12,3 y 20,3 puntos mayor por unidad, según la competencia. La de zona no lo es (p = 0,082). **H6 se acepta por sector.**

Cuadro 19: Robustez: SEM con NSE latente frente al enfoque en dos pasos (D-42, punto 4).

Competencia	NSE	SEM latente (por DE)	Dos pasos (por DE)	Razón
emplear	económico	23,20	24,15	1,041
emplear	libros	7,82	6,96	0,890
formular	económico	23,59	24,84	1,053
formular	libros	13,79	12,10	0,877
interpretar	económico	28,69	29,43	1,026
interpretar	libros	8,68	8,06	0,929
razonar	económico	23,12	24,27	1,050
razonar	libros	10,89	9,38	0,861

Cuadro 20: Robustez con los puntajes propios: concordancia con los VP de la OCDE (D-44).

Prueba	Unidad	OCDE	p OCDE	Propios	p propios	Coincide
NSE económico, emplear	coeficiente estandarizado	0,327	3,5e-41	0,335	3,1e-54	sí
NSE económico, formular	coeficiente estandarizado	0,280	6,1e-17	0,322	3,2e-45	sí
NSE económico, interpretar	coeficiente estandarizado	0,350	5,5e-40	0,367	2,0e-69	sí
NSE económico, razonar	coeficiente estandarizado	0,283	2,0e-19	0,315	3,6e-47	sí
R^2 medio, emplear	proporción de varianza	0,298		0,364		
R^2 medio, formular	proporción de varianza	0,244		0,338		
R^2 medio, interpretar	proporción de varianza	0,310		0,350		
R^2 medio, razonar	proporción de varianza	0,238		0,337		
Igualdad del NSE económico entre competencias (6.4)	chi2 de Wald, 3 gl	11,320	1,0e-02	38,080	2,7e-08	sí
H5, interpretar - emplear, completa (6.886)	puntos PISA (OCDE) / DE latentes (propios)	5,570	1,0e-03	0,035	8,5e-06	sí
H5, interpretar - emplear, mitad de confirmación (3441)	puntos PISA (OCDE) / DE latentes (propios)	6,330	3,7e-04	0,039	6,8e-04	sí
H6, zona (NSE x pueblo y NSE x rural)	chi2 de Wald; p con Holm	13,990	8,2e-02	83,580	1,9e-14	no
H6, sector (NSE x privado)	chi2 de Wald; p con Holm	15,580	7,3e-03	68,540	4,6e-14	sí

Robustez de la F6.

- *NSE latente:* el SEM con el NSE latente da casi los mismos coeficientes del NSE económico (el enfoque en dos pasos queda entre 2,6 y 5,3 % por encima), y el orden de las competencias se mantiene.
- *Puntajes propios (D-44):* se repiten el orden de las competencias, el rechazo de la igualdad, H5 y H6 por sector. La única discrepancia es NSE × zona, muy significativa con los propios y no con los de la OCDE. *(Interpretación:)* hay dos sesgos posibles en sentidos opuestos —los VP propios pueden dar valores p demasiado pequeños y los de la OCDE pueden atenuar la interacción si su modelo de condicionamiento no la incluye, lo que no se ha verificado en el Technical Report—, así que **H6 por zona queda sin resolver**.
- *Ajuste del SEM latente* (descriptivo, solo con el VP1): CFI *scaled* 0,927, RMSEA *scaled* 0,050 y SRMR 0,070. `lavaan` no pudo calcular las versiones *robust*, y las *scaled* tienden a ser optimistas, así que no se puede afirmar que el ajuste sea bueno.

9. Robustez (F7)

Diseño (D-45, fijado antes de correr). Se pusieron a prueba cinco resultados candidatos con cinco sensibilidades:

- **S-A:** usar el ESCS oficial en lugar del NSE latente.
- **S-B:** excluir a los estudiantes de la ruta lineal de la prueba.
- **S-C:** cambiar el umbral de omisión rápida (NT15 y 5 segundos).
- **S-D:** no corregir por comparaciones múltiples.
- **S-E:** reponderar por la exclusión no aleatoria dentro del colegio (D-38).

Cada sensibilidad se aplica solo a los candidatos donde tiene sentido. Un candidato es **robusto** si su conclusión se mantiene en al menos el 75 % de las sensibilidades que le aplican, con un mínimo de 3.

Cuadro 21: Robustez de los candidatos (07_sensibilidad.R, D-45).

Candidato	Conclusión	Aplicables	Se mantiene	Requerido	Robusto
K1	igualdad rechazada y H5 con su regla (completa y mitad)	3	3	3	sí
K2	NSE x sector significativa (H6)	4	4	3	sí
K3	NSE > 0 y significativo en las 4 competencias	3	3	3	sí
K4	H4 se rechaza (nulo)	5	5	4	sí
K5	H3: primera parte sí, segunda no	4	4	3	sí

Cuadro 22: Resultado de cada sensibilidad; el detalle numérico está en salidas/f7_sensibilidad_detalle.csv.

Candidato	Sensibilidad	Se mantiene
K1	base (análisis principal)	sí
K1	S-A ESCS	sí
K1	S-B sin ruta lineal	sí
K1	S-E reponderación D-38	sí
K2	base (análisis principal)	sí
K2	S-A ESCS	sí
K2	S-B sin ruta lineal	sí
K2	S-D sin corrección múltiple	sí
K2	S-E reponderación D-38	sí
K3	base (análisis principal)	sí
K3	S-A ESCS	sí
K3	S-B sin ruta lineal	sí
K3	S-E reponderación D-38	sí
K4	base (análisis principal)	sí
K4	S-A ESCS	sí
K4	S-B sin ruta lineal	sí
K4	S-C umbral de omisión (NT15 y 5 s)	sí
K4	S-D sin corrección múltiple	sí
K4	S-E reponderación D-38	sí
K5	base (análisis principal)	sí
K5	S-A ESCS	sí
K5	S-B sin ruta lineal	sí
K5	S-D sin corrección múltiple	sí
K5	S-E reponderación D-38	sí

Resultado. Los 5 candidatos son robustos (5 de 5). Hay tres matices que se declaran (D-45):

- **K1 queda cerca del límite.** Con ESCS, la diferencia interpretar − emplear baja a 3,72 puntos, y sin la ruta lineal la igualdad sale con p = 0,049 (`salidas/f7_sensibilidad_detalle.csv`).

- **NSE × zona con ESCS.** Con el ESCS oficial, la interacción NSE × zona también sale significativa; no lo es en la base.
- **El DIF varía poco entre variantes.** Con cuartiles de ESCS hay 6 ítems con DIF y sin la ruta lineal, 2. En ningún caso se concentra en interpretar y formular. `CMA135Q04S` tiene DIF en todas las variantes y siempre favorece al cuartil bajo.

Reproducción en otro equipo. La cadena completa (`scripts/00_correr_todo.R`) y las dos variantes largas del DIF se volvieron a correr desde cero en un segundo computador. Ninguna conclusión cambió: las variantes del DIF marcan los mismos ítems, y las demás salidas difieren solo en decimales o en los minutos de cómputo (D-45). Las tablas de este informe usan los archivos de la primera corrida.

10. Hallazgos y discusión

Cada candidato se clasificó con los cinco criterios de la rúbrica (`Vault_PISA2022/08 Rúbrica de desarrollo.md`):

1. hipótesis preregistrada o exploratoria declarada;
2. efecto relevante según el umbral fijado antes;
3. robustez según D-45;
4. ausencia de antecedente para Colombia;
5. explicable en una frase.

El detalle de la clasificación está en `Vault_PISA2022/Hallazgos.md`. Para el criterio 4, la búsqueda de novedad del paso 7.2 cubrió un buscador web general, SciELO, Redalyc, Scopus y Google Académico (primera página de cada cadena), y en ninguno apareció un antecedente para Colombia de K1, K2, K4 ni K5. En Scopus, 7 de las 10 cadenas dieron cero resultados y las otras 3, un documento cada una, ninguno sobre Colombia. Sí aparecieron análisis parecidos en otros países o poblaciones: el informe nacional de Inglaterra, que según su resumen revisa si la brecha por NSE cambia entre procesos matemáticos (K1), el efecto del tratamiento de las omisiones en comparaciones entre grupos (K4) y, en primaria de América Latina con el SERCE de 2006, un estudio del BID que probó la misma interacción de K2 y no la encontró significativa para Colombia en ninguna de sus cuatro pruebas (Duarte et al., 2010, pp. 20-21). Los otros tres posibles antecedentes que aparecieron se revisaron y no lo son: uno usa el puntaje total de matemáticas, otro busca DIF por sexo en el TERCE y el tercero estudia Chile y México (`Vault_PISA2022/Literatura/Búsqueda de novedad F7.md`). Con esa búsqueda, el equipo da por cumplido el criterio 4 para K1, K2, K4 y K5. No haber encontrado un antecedente no prueba que no exista: la búsqueda tiene la cobertura y la fecha que se documentan.

Cuadro 23: Clasificación de los candidatos (Hallazgos.md). Robustez leída de f7_robustez.csv.

Candidato	Resultado	Clasificación	Robusto
K1	El NSE económico se asocia más con interpretar que con emplear	Hallazgo exploratorio (requiere confirmación en otra muestra o ciclo)	3 de 3
K2	La pendiente del NSE es mayor en los colegios privados	Hallazgo	4 de 4
K3	El NSE económico se asocia con las 4 competencias	Réplica, extendida a las 4 competencias	3 de 3
K4	Tratar las omisiones rápidas como faltantes no reduce la brecha	Resultado nulo bien medido	5 de 5
K5	DIF por NSE escaso y no concentrado en interpretar y formular	Hallazgo parcial: la primera parte de H3 se sostiene; el patrón por competencia, no	4 de 4

Lectura de conjunto *(interpretación)*:

1. **La brecha no es un artefacto de la calificación.** Ni el tratamiento de las omisiones (K4) ni el funcionamiento de los ítems (K5) cambian la brecha de forma relevante: el desenganche rápido no la explica y los pocos ítems con DIF van en los dos sentidos. Esto responde la segunda parte de la pregunta de investigación: en estos datos, la brecha casi no depende de esas decisiones de calificación.
2. **Las competencias se distinguen poco.** La asociación con el NSE es algo mayor en interpretar (K1), pero la diferencia es pequeña frente al tamaño de la asociación (K3) y descansa en competencias que casi no se separan empíricamente (H8, H7). Por eso K1 se reporta como exploratorio.
3. **El sector importa más que la zona.** La pendiente del NSE es más empinada en los colegios privados (K2). Esto no dice que los colegios privados «causen» desigualdad: puede reflejar cómo se reparten los estudiantes entre colegios (composición y selección), algo que este diseño no separa. En primaria, con el SERCE de 2006, la misma interacción no fue significativa para Colombia, aunque la pendiente del NSE entre escuelas era más pronunciada en las privadas en América Latina (Duarte et al., 2010, pp. 19-21). La diferencia con nuestro resultado puede deberse a la edad, al año o al modelo, y no se puede separar con estos datos.
4. **La medición del NSE es la parte más débil.** Dos dimensiones se sostienen (H1), pero el ajuste no llega a los cortes y la invarianza no se demostró (D-35). Las conclusiones sobre el NSE económico son estables con el ESCS oficial (S-A), lo que da algo de tranquilidad.

Frases para el Ministerio de Educación (criterio 5):

- **K1 (exploratorio):** «En Colombia, la ventaja de los estudiantes de hogares con más recursos es algo mayor cuando deben interpretar resultados matemáticos que cuando deben aplicar procedimientos.»
- **K2:** «En los colegios privados, la diferencia de desempeño en matemáticas entre estudiantes de hogares con más y con menos recursos es mayor que en los públicos.»
- **K3:** «Los estudiantes de hogares con más recursos rinden más en las cuatro formas de usar las matemáticas que mide PISA, no solo en el puntaje total.»
- **K4:** «Las respuestas dejadas en blanco muy rápido no explican la brecha socioeconómica en matemáticas.»
- **K5:** «Muy pocas preguntas de matemáticas de PISA funcionan distinto según los recursos del hogar, y las que lo hacen no favorecen de forma sistemática a los de más recursos.»

Riesgos de mal uso.

- **K1 y K3** describen promedios condicionados, no capacidades individuales. Si se reportan sin esa salvedad, hay riesgo de estigmatizar a los estudiantes de NSE bajo.
- **K5** no dice que la prueba sea «justa» en todo. Un ítem con DIF no es necesariamente injusto, y la revisión de contenido de los ítems marcados sigue pendiente. Tampoco descarta un sesgo común a todos los ítems: el DIF compara cada ítem con el resto de la prueba.

11. Limitaciones

1. **Diseño transversal** de un solo ciclo y un solo país: todas las relaciones son asociaciones, no efectos causales.
2. **Ajuste del NSE** por debajo de los cortes en las versiones *robust* (D-18, D-24). El factor de libros es menos preciso de lo que indica el modelo principal (S1, D-35).
3. **Invarianza no demostrada:** el criterio preregistrado no detecta no invarianza relevante, pero la prueba χ^2 la rechaza y el ajuste de partida es pobre (D-35).
4. **Exclusión no aleatoria:** los excluidos rinden menos (D-14). La reponderación por colegio (S-E) no cambia las conclusiones, pero solo corrige la parte de la exclusión que se explica por el colegio.

5. **Competencias muy correlacionadas** y pocos ítems por estudiante en cada una (D-27, D-29). Esto limita los puntajes propios y obligó a usar los VP de la OCDE como principales (D-32). Falta verificar en el Technical Report qué variables usa la OCDE para condicionar sus VP, lo que afecta la lectura de H6 por zona.
6. **Errores de diseño solo en las cifras finales** (D-34). El AFC, la TRI y el DIF son estimaciones puntuales cuyos errores no reflejan el muestreo por colegios.
7. **Decisiones posteriores a ver resultados**, declaradas como tales: D-32 (orden de las fuentes de O4 y H5 exploratoria), D-33 (E1 después del fallo de V1), D-43 (enlace robusto de P3) y D-48 (análisis confirmatorio por competencia, exploratorio).
8. **Pendientes que no se hicieron** (D-21, D-45): la revisión de contenido de los ítems con DIF (P4), la calibración sin los ítems con menos de 500 respuestas (P2), un tercer tratamiento de las omisiones (P5), la lectura en texto completo de los antecedentes encontrados en la búsqueda de novedad y la verificación de la mayoría de las fuentes citadas.

12. Productos: API y tablero (O5, F8)

Los resultados agregados se publican en una API REST (FastAPI, Python 3.11.9; `Proyecto_PISA/api/`, D-46) y en un tablero en Streamlit que la consume (`Proyecto_PISA/tablero/`, D-47). El código, las salidas agregadas, el vault con las decisiones y este informe están en el repositorio público https://github.com/osmateoramos/Proyecto-Final-PISA.

- **API:** solo lee los archivos de `salidas/`, no estima nada y nunca entrega datos por estudiante. Tiene documentación OpenAPI en `/docs`, versión `/v1` y un endpoint de predicción con los coeficientes de la F6.
- **Tablero:** recorre el proyecto fase por fase, con textos que explican cada resultado y el diagrama interactivo del modelo estructural.
- **Calidad:** los dos tienen pruebas automáticas (`pytest`), Dockerfile e integración continua en GitHub Actions.
- **Despliegue:** los dos están publicados en Render, en el plan gratuito, con la configuración de `render.yaml` (en la raíz del repositorio). La API está en https://pisa-api-k2tn.onrender.com (documentación en https://pisa-api-k2tn.onrender.com/docs) y el tablero en https://pisa-tablero.onrender.com. En el plan gratuito los servicios se apagan cuando no se usan, así que la primera visita puede tardar 50 segundos o más.

13. Conclusiones

1. El NSE de los estudiantes colombianos de PISA 2022 se mide mejor con dos dimensiones (económica y de libros) que con una. Con el criterio preregistrado no se detectaron diferencias relevantes en su medición entre zonas, sexos y sectores, aunque la invarianza no queda demostrada.
2. El NSE económico se asocia con las cuatro competencias matemáticas con una magnitud similar, entre 24,2 y 29,4 puntos PISA por DE. La asociación es algo mayor en interpretar, como resultado exploratorio, y es más fuerte dentro de los colegios privados.
3. La brecha socioeconómica casi no depende de cómo se califican las omisiones y no la explican ítems con DIF: en estos datos no es un artefacto de la calificación.
4. Las cuatro competencias se distinguen poco con los ítems que ve cada estudiante en el diseño adaptativo. Para analizarlas por separado conviene usar los VP de la OCDE y tratar con cautela cualquier puntaje propio por competencia.
5. Los cinco resultados principales se mantienen en las sensibilidades de la fase de robustez. En Scopus, Google Académico, SciELO y Redalyc no apareció un antecedente para Colombia de K1, K2, K4 ni K5. Los antecedentes más cercanos son de otros países o poblaciones; el de K2, en primaria, no encontró la interacción para Colombia.

14. Declaración de uso de IA y reparto del trabajo

Uso de inteligencia artificial. El equipo usó un asistente de IA generativa (Claude, de Anthropic, mediante Claude Code) durante todo el proyecto, como se registra fila por fila en `Vault_PISA2022/15 Bitácora de uso de IA.md`. Según esa bitácora, la IA se usó para:

1. revisar la base de PISA 2022 y escribir los scripts en R de las fases F1 a F7;
2. buscar antecedentes y verificar metadatos bibliográficos;
3. redactar como propuestas buena parte de las decisiones del registro, con alternativas para que el equipo eligiera;
4. programar la API y el tablero siguiendo el documento de buenas prácticas del curso de Python;
5. redactar borradores, entre ellos **este informe**, que Claude escribió el 2026-11-10 a partir de las salidas y del vault, y cuya versión de entrega cerró el equipo ese mismo día.

Qué no hizo la IA. Según el registro y la bitácora:

- No tomó las decisiones metodológicas: las aceptó o modificó un integrante, casi siempre Vanessa, y Mateo y Brayan las revisan en los PR.
- No marcó ninguna fuente como verificada.
- No decidió qué se reporta como hallazgo.

Errores de la IA detectados y corregidos. El protocolo de verificación (`Vault_PISA2022/11 Protocolo de verificación.md`) detectó errores propios de la IA, que quedaron registrados:

- números de página del Technical Report mal leídos (F2);
- códigos de no respuesta que un script propio contaba como faltantes (F1);
- cargas en 0 en una salida propia por un comportamiento de `mirt` que no se había revisado (F3);
- un conteo de omisiones mal hecho (F5);
- un diseño de enlace de dificultades que no anticipó ítems con discriminación casi nula (D-41 y D-43);
- infinitos no tratados en una salida del DIF (D-40);
- conclusiones de la F4 redactadas con más fuerza de la que daban los datos (D-35).

Reparto del trabajo. El equipo mantiene el reparto del anteproyecto: cada fase tuvo un responsable principal y otro integrante la revisó, y los tres participaron en los objetivos, en las decisiones del registro y en la verificación de fuentes.

Cuadro 24: Reparto del trabajo (el del anteproyecto, confirmado por el equipo).

Sección / fase	Responsable principal	Revisión cruzada
Planteamiento del problema	Vanessa Acosta	Mateo Ramos
Estado del arte	Mateo Ramos	Brayan David Barreto
Objetivos	Los tres	—
Datos, NSE e invarianza (objetivos 1–2)	Mateo Ramos	Brayan David Barreto
Calificación por competencias y DIF (objetivo 3)	Vanessa Acosta	Mateo Ramos
Modelo estructural (objetivo 4)	Brayan David Barreto	Vanessa Acosta
API y tablero (objetivo 5)	Brayan David Barreto	Mateo Ramos
Gestión de la información y verificación de fuentes	Los tres	—

15. Anexo: glosario de siglas, códigos e indicadores

Este anexo explica las siglas y los códigos que usa el informe. Las definiciones de los códigos del proyecto vienen del plan (`Vault_PISA2022/07 Plan de desarrollo PISA 2022.md`), de la rúbrica (`08 Rúbrica de desarrollo.md`) y del registro de decisiones (`03 Registro de decisiones.md`).

15.1. Códigos del proyecto

Código	Qué es
O1–O5	Objetivos específicos (sección «Objetivos e hipótesis»): O1 medir el NSE; O2 verificar su invarianza; O3 calificar por competencias y verificar la equidad de la calificación; O4 explicar el desempeño por competencia con un modelo estructural; O5 publicar los resultados en una API y un tablero
H1–H8	Hipótesis preregistradas antes de analizar los datos (tabla de la sección «Objetivos e hipótesis»)
F1–F9	Fases del plan de trabajo: F1 datos y depuración; F2 validación del diseño muestral; F3 medición del NSE (O1); F4 invarianza del NSE (O2); F5 calificación por competencias (O3); F6 modelo estructural (O4); F7 robustez y verificación de novedad; F8 API y tablero (O5); F9 informe y sustentación
G1–G4	Puertas de fase: condiciones que deben cumplirse para pasar a la siguiente fase. **G1** (al cerrar la F2): la media, la brecha y el porcentaje de varianza coinciden con los de la OCDE (± 1). **G2** (F3): el modelo del NSE tiene un ajuste aceptable o un desajuste documentado, y H1 está resuelta. **G3** (F5): los ítems con pocas respuestas están excluidos y listados, y H3 y H4 están resueltas. **G4** (F7): los resultados están congelados con una etiqueta en Git (`resultados-v1`)
D-01, D-02...	Decisiones del registro, numeradas en orden. Cada una dice el problema, las alternativas, lo que se decidió, quién lo decidió y cuándo, y se registró **antes** de programarla
K1–K5	Candidatos a hallazgo evaluados en la F7: K1, el NSE económico se asocia más con interpretar que con emplear; K2, la pendiente del NSE es mayor en los colegios privados; K3, el NSE se asocia con las 4 competencias; K4, tratar las omisiones rápidas como faltantes no reduce la brecha; K5, el DIF por NSE es escaso
S-A a S-E	Sensibilidades de la F7 (D-45): S-A, el ESCS oficial en lugar del NSE latente; S-B, sin los estudiantes de la ruta lineal; S-C, otro umbral de omisión rápida (NT15 y 5 segundos); S-D, sin corrección por comparaciones múltiples; S-E, reponderación por la no respuesta dentro del colegio (D-38)
S1, S2	Sensibilidades de las F3 y F4 (D-35): S1, las preguntas saltadas cuentan como faltantes y no como 0 (D-20); S2, el DIF de las posesiones se empareja con un modelo multigrupo
P2–P5	Mejoras metodológicas aprobadas en D-21: P2, calibrar sin los ítems con menos de 500 respuestas; P3, comparar las dificultades de los ítems con las internacionales; P4, un análisis del DIF más completo, con la revisión del contenido de los ítems marcados; P5, un tercer tratamiento de las omisiones
E1	Método de integración de los puntajes propios: cuadratura de Gauss-Hermite adaptativa (D-31, D-33)
V1–V3	Criterios para aceptar los puntajes propios (D-27): V1, coinciden con los de `mirt` sin covariables; V2, las EAP no cambian al duplicar los puntos de integración; V3, los errores estándar tampoco cambian
NT10, NT15	Umbrales de omisión rápida: una omisión es rápida si se hizo en menos del 10 % (NT10) o del 15 % (NT15) del tiempo medio que dedicaron al ítem quienes lo vieron
Q1, Q4	Cuartil más bajo y más alto del NSE económico
VP, VP1	Valores plausibles; VP1 es el primero de los diez

15.2. Siglas y términos estadísticos

Sigla	Significado
NSE	Nivel socioeconómico. En este informe es una variable latente con dos dimensiones: económica y de libros en el hogar
ESCS	Índice oficial de PISA de estatus económico, social y cultural
HOMEPOS	Índice de PISA de posesiones del hogar
HISEI / HISCED	Ocupación más alta de los padres (índice ISEI) y educación más alta de los padres (clasificación ISCED)
INSE	Índice de nivel socioeconómico del Icfes
TRI	Teoría de respuesta al ítem. **2PL**: modelo logístico de dos parámetros, para ítems de sí o no; **GPCM**: modelo de crédito parcial generalizado, para ítems con más de dos categorías
AFE / AFC	Análisis factorial exploratorio / confirmatorio
SEM	Modelos de ecuaciones estructurales
WLSMV	Estimador de mínimos cuadrados ponderados con media y varianza ajustadas, para datos ordinales
CFI, RMSEA, SRMR	Índices de ajuste: índice de ajuste comparativo, error cuadrático medio de aproximación y residuo cuadrático medio estandarizado. *Scaled* y *robust* son dos correcciones para datos no normales; ΔCFI y ΔRMSEA son sus cambios entre dos modelos
BIC	Criterio de información bayesiano: entre dos modelos, el de menor BIC equilibra mejor ajuste y complejidad
DIF	Funcionamiento diferencial del ítem: estudiantes con el mismo nivel en la competencia tienen distinta probabilidad de acertar el ítem según su grupo
ΔMH, ETS (A, B, C)	Magnitud del DIF por Mantel-Haenszel y su clasificación del Educational Testing Service: A despreciable, B moderado, C grande
BH, Holm	Correcciones por comparaciones múltiples (Benjamini-Hochberg y Holm)
EAP	Puntaje estimado como la media de la distribución posterior de cada estudiante
VP	Valores plausibles: puntajes simulados que PISA entrega para estimar promedios y asociaciones con su incertidumbre
BRR	Réplicas repetidas balanceadas (con el ajuste de Fay): el método de PISA para calcular errores estándar con el diseño muestral
EM	Algoritmo de esperanza-maximización
DE, EE, IC	Desviación estándar, error estándar e intervalo de confianza
PISA, OCDE	Programa para la Evaluación Internacional de Estudiantes, de la Organización para la Cooperación y el Desarrollo Económicos
SERCE, TERCE	Segundo y Tercer Estudio Regional Comparativo y Explicativo de la UNESCO (primaria, América Latina)
API	Interfaz de programación: el servicio web que publica los resultados del proyecto

15.3. Los 29 indicadores del NSE

Los indicadores salen del cuestionario del estudiante de PISA 2022. Las descripciones son traducciones de las etiquetas del libro de códigos (`salidas/nse_items_frecuencias.csv`). El factor es el del análisis factorial exploratorio que eligió la Puerta G2 (D-24; `salidas/nse_estructura_afe.csv`); el factor «cultural» es el que el informe llama de libros.

Cuadro 25: Los 29 indicadores del NSE, su factor en el AFE y su carga principal (D-24).

Código del indicador	Descripción	Factor (AFE)	Carga
ST254Q05JA	Lectores de libros electrónicos, como Kindle (cuántos)	cultural	0,285
ST255Q01JA	Libros en el hogar (cuántos)	cultural	0,786
ST256Q01JA	Libros religiosos	cultural	0,766
ST256Q02JA	Literatura clásica	cultural	0,788
ST256Q03JA	Literatura contemporánea	cultural	0,751
ST256Q06JA	Libros de ciencia	cultural	0,790
ST256Q07JA	Libros de arte, música o diseño	cultural	0,728
ST256Q08JA	Libros técnicos de consulta	cultural	0,690
ST256Q09JA	Diccionarios	cultural	0,845
ST256Q10JA	Libros para ayudar con las tareas escolares	cultural	0,792
HISCED_c	Educación más alta de los padres (ISCED, en categorías)	económico	0,446
HISEI_q	Ocupación más alta de los padres (índice HISEI, en cuartiles)	económico	0,538
ST250Q01JA	Una habitación propia	económico	0,435
ST250Q02JA	Un computador (portátil, de escritorio o tableta) para las tareas escolares	económico	0,876
ST250Q03JA	Software o aplicaciones educativas	económico	0,548
ST250Q04JA	Un celular propio con acceso a internet	económico	0,653
ST250Q05JA	Acceso a internet en el hogar (sin contar el del celular)	económico	0,783
ST251Q01JA	Carros, camionetas o camiones (cuántos)	económico	0,660
ST251Q02JA	Motos o ciclomotores (cuántos)	económico	0,207
ST251Q03JA	Cuartos con baño o ducha (cuántos)	económico	0,619
ST251Q04JA	Cuartos con sanitario (cuántos)	económico	0,641
ST251Q06JA	Instrumentos musicales (cuántos)	económico	0,374
ST251Q07JA	Obras de arte (cuántas)	económico	0,469
ST253Q01JA	Dispositivos digitales con pantalla en el hogar (cuántos)	económico	0,732
ST254Q01JA	Televisores (cuántos)	económico	0,701
ST254Q02JA	Computadores de escritorio (cuántos)	económico	0,684
ST254Q03JA	Computadores portátiles (cuántos)	económico	0,766
ST254Q04JA	Tabletas (cuántas)	económico	0,530
ST254Q06JA	Celulares con acceso a internet (cuántos)	económico	0,706

Referencias

Avvisati, F., & Wuyts, C. (2024). *The Measurement of Socio-economic Status in PISA* (OECD Education Working Papers No. 321). OECD Publishing. https://doi.org/10.1787/0c5b793c-en

Chalmers, R. P. (2012). mirt: A Multidimensional Item Response Theory Package for the R Environment. *Journal of Statistical Software*, *48*(6). https://doi.org/10.18637/jss.v048.i06

Collazos Valenzuela, A. C., Quintero Medina, M. V., & Trujillo Caicedo, K. N. (2021). Determinantes del rendimiento académico de la prueba Saber 11 en Colombia durante el periodo 2014-2019. *Panorama*, *15*(29). https://www.redalyc.org/journal/3439/343967896009/html/

Duarte, J., Bos, M. S., & Moreno, M. (2010). *¿Enseñan mejor las escuelas privadas en América Latina? Estudio comparativo usando los resultados del SERCE* (Notas técnicas No. 5). Banco Interamericano de Desarrollo, División de Educación. https://webimages.iadb.org/publications/spanish/document/%C2%BFEnse%C3%B1an-mejor-las-escuelas-privadas-en-Am%C3%A9rica-Latina-Estudio-comparativo-usando-los-resultados-del-SERCE.pdf

Eriksson, K., Lindvall, J., Helenius, O., & Ryve, A. (2021). Socioeconomic status as a multidimensional

predictor of student achievement in 77 societies. *Frontiers in Education*, *6*, 731634. https://doi.org/10.3389/feduc.2021.731634

García-Medina, A. M., Martínez Rizo, F., & Cordero Arroyo, G. (2016). Análisis del funcionamiento diferencial de los ítems del Excale de matemáticas para tercero de secundaria. *Revista Mexicana de Investigación Educativa*, *21*(71). https://www.redalyc.org/journal/140/14047430009/html/

Goh, S., Woo, Y., Lee, J.-Y., Choi, H., & Choi, Y.-J. (2024). Detection of differential item functioning in PISA 2022 mathematics test using the Rasch tree method. *Journal of Educational Evaluation*, *37*(4), 803-834. https://doi.org/10.31158/jeev.2024.37.4.803

Hernández Padilla, E., & González Montesinos, M. J. (2011). Modelo de ecuación estructural que evalúa las relaciones entre el estatus cultural y económico del estudiante y el logro educativo. *Revista Electrónica de Investigación Educativa (REDIE)*, *13*(2), 188-203. https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S1607-40412011000200011

Icfes. (2024). *Programa para la Evaluación Internacional de Alumnos (PISA). Informe nacional de resultados para Colombia 2022*. Icfes. https://www.mineducacion.gov.co/1780/articles-421217_recurso_03.pdf

Instituto Colombiano para la Evaluación de la Educación (ICFES). (2019). *¿Cómo se construye el Índice de Nivel Socioeconómico (INSE) en el contexto de las pruebas Saber?* [Boletín Saber al Detalle, Edición 04]. ICFES. https://www.icfes.gov.co/wp-content/uploads/2024/11/Edicion-4-boletin-saber-al-detalle-.pdf

Köhler, C., Pohl, S., & Carstensen, C. H. (2015). Taking the Missing Propensity Into Account When Estimating Competence Scores. *Educational and Psychological Measurement*, *75*(5), 850-874. https://doi.org/10.1177/0013164414561785

Laboratorio de Economía de la Educación (LEE), Pontificia Universidad Javeriana. (2024). *Pruebas Saber 11: una década de análisis* [Informe de análisis estadístico LEE, núm. 92]. Pontificia Universidad Javeriana. https://www.javeriana.edu.co/recursosdb/5581483/11594517/INF-92-Analisis-Decada-Saber11-LEE2024.pdf

Mittal, O., Scherer, R., & Nilsen, T. (2022). Assessing the evidence for the comparability of socioeconomic status between students with and without immigrant background in Norway and Sweden. *Large-scale Assessments in Education*, *10*(1), 13. https://doi.org/10.1186/s40536-022-00132-w

OECD. (2023). *PISA 2022 Database*. https://www.oecd.org/en/data/datasets/pisa-2022-database.html

OECD. (2024). *PISA 2022 Technical Report*. OECD Publishing. https://www.oecd.org/content/dam/oecd/en/publications/reports/2024/03/pisa-2022-technical-report_599753f0/01820d6d-en.pdf

Pohl, S., Gräfe, L., & Rose, N. (2014). Dealing With Omitted and Not-Reached Items in Competence Tests. *Educational and Psychological Measurement*, *74*(3), 423-452. https://doi.org/10.1177/0013164413504926

Rios, J. A., & Soland, J. (2022). An investigation of item, examinee, and country correlates of rapid guessing in PISA. *International Journal of Testing*, *22*(2), 154-184. https://doi.org/10.1080/15305058.2022.2036161

Rodriguez-Gómez, W. F., Rodríguez Gómez, E. Y., & Gomez-Gonzalez, J. E. (2024). The Rural-Urban Student Performance Gap in Colombia. *Desarrollo y Sociedad*, (97), 59-75. https://doi.org/10.13043/dys.97.3

Rosseel, Y. (2012). lavaan: An R Package for Structural Equation Modeling. *Journal of Statistical Software*, *48*(2). https://doi.org/10.18637/jss.v048.i02

Rubin, D. B. (1987). *Multiple Imputation for Nonresponse in Surveys*. Wiley. https://doi.org/10.1002/9780470316696

Sokolov, B. (2019). *Sensitivity of Goodness of Fit Indices to Lack of Measurement Invariance with Categorical Indicators and Many Groups* (Basic Research Program Working Papers, Series: Sociology WP BRP 86/SOC/2019). National Research University Higher School of Economics. https://ssrn.com/abstract=3417157

Wu, H., & Estabrook, R. (2016). Identification of Confirmatory Factor Analysis Models of Different Levels of Invariance for Ordered Categorical Outcomes. *Psychometrika*, *81*(4), 1014-1045. https://doi.org/10.1007/s11336-016-9506-0