Nada sin fuente: experimento y decisión

Consultoría Estadística — Proyecto PISA 2022 Colombia

Vanessa Acosta, Mateo Ramos y Brayan David Barreto

Universidad Santo Tomás · 2026-II

1. Diseño

Tres consultas bibliográficas reales, una por integrante: invarianza del NSE de PISA dentro de un país (Mateo), DIF por NSE en las competencias matemáticas (Vanessa) y SEM con valores plausibles y pesos (Brayan). Cada una se corrió con el mismo texto en **A**, Claude en un chat nuevo sin búsqueda web (control); **B**, Claude Code respondiendo solo con las notas del vault de Obsidian y el protocolo de consulta; y **C**, NotebookLM con los PDF del corpus. Se contó toda referencia a la que la herramienta le atribuye contenido, también las «cercanas»; la abstención y las fuentes que la herramienta nombra solo para descartarlas se anotan aparte. Los tres clasificaron por separado, sin ver el tratamiento y en orden aleatorio, en *utilizable*, *existe pero no dice eso* o *no existe*; la etiqueta final es la de la mayoría de quienes clasificaron, y sin mayoría la referencia sale de las proporciones.

Desvíos que declaramos. (1) No hubo buscador: se mide anclaje, no búsqueda. (2) El cuaderno de NotebookLM no tuvo el mismo contenido en todas las corridas: la primera C de Brayan se hizo con 13 entradas (4 duplicadas) y se repitió con 27; la de Mateo tuvo 36 (32 sin repetidos). (3) Una corrida de B leyó la respuesta de A fuera del vault y se descartó; desde entonces B se abre en `Vault_PISA2022` con el protocolo v2. (4) Seis fuentes que B nombró solo para descartarlas llegaron a la hoja sin título y casi todas se marcaron «no existe», aunque existen; se sacaron después de clasificar y se informa también el resultado contándolas. (5) Vanessa dejó sin categoría las 21 referencias de pago, casi todas de A; en ellas la etiqueta cuenta solo si Brayan y Mateo coinciden. (6) Mateo y Brayan usaron el mismo modelo en A y B (Opus 5.5); Vanessa, Opus 5.5 en A y Sonnet 5 en B. Cada corrida está registrada en `experimento/consulta_{persona}.md`.

2. Resultados

Cuadro 1: Etiqueta final por mayoría (U utilizable, E existe pero no dice eso, N no existe), proporción de utilizables (IC de Wilson), rango si las referencias sin mayoría fueran todas no utilizables o todas utilizables, y diferencia frente a A (IC de Newcombe; p de Fisher). Sin las seis descartadas; contándolas, B pasaría a 0,65 (n = 23).

Tratamiento	U / E / N / sin mayoría	Utilizables (IC 95 %)	Con las sin mayoría	Diferencia con A (IC 95 %); p
A · Claude sin contexto	11 / 2 / 0 / 9	0,85 (0,58–0,96)	0,50 a 0,91	—
B · Zotero + Obsidian	15 / 2 / 1 / 2	0,83 (0,61–0,94)	0,75 a 0,85	-0,01 (-0,26 a +0,28); 1,00
C · NotebookLM	12 / 5 / 0 / 2	0,71 (0,47–0,87)	0,63 a 0,74	-0,14 (-0,40 a +0,17); 0,43

Qué se puede concluir. Poco. Cada proporción sale de 13 a 18 referencias, los intervalos se traslapan y las diferencias frente a A incluyen el cero (p = 1,00 y 0,43). Las referencias de una misma consulta comparten respuesta,

tema y modelo, así que el número efectivo de observaciones está más cerca de tres consultas por tratamiento, y los intervalos reales serían más anchos. Además, las referencias sin mayoría no se reparten igual: en A son 9, todas de pago, y según cómo se cuenten A queda entre 0,50 y 0,91, mientras B se mueve entre 0,75 y 0,85. El experimento no permite decir que A supere a B; sí muestra que B es el resultado que menos depende de la clasificación.

Acuerdo de la clasificación. Hubo desacuerdo en 23 de las 40 referencias que clasificaron los tres (kappa de Fleiss 0,062, apenas mayor que el azar). En 20 de esos desacuerdos la duda era entre «utilizable» y «existe pero no dice eso»: si el documento dice lo que se le atribuye, no si existe. Vanessa marcó como utilizables casi todas las que clasificó y Brayan fue el más estricto, así que las proporciones dependen de quién clasifica. Detalle en `salidas/nsf_acuerdo.csv` y `nsf_desacuerdos.csv`.

3. Decisión

Cuadro 2: Tabla de decisión resumida (la completa, con la evidencia de cada celda, está en tabla_decision.md).

Criterio	A · Claude sin contexto	B · Zotero + Obsidian	C · NotebookLM
Contexto cerrado	No: responde de memoria	Sí, con la sesión en el vault (v2)	Sí: solo el cuaderno
Cita con localización	DOI, sin página	Nota, página y estado	Documento; página variable
Base verificada	No lee fuentes	Solo si la nota está verificada	Lee el PDF cargado
Privacidad	La pregunta va a Anthropic	Las notas van a Anthropic; los PDF quedan locales	Los PDF se suben a Google
Exportación a APA 7	No	Sí (Zotero + Better BibTeX)	No
Reproducibilidad	Baja	Media (vault y protocolo en Git)	Baja (el cuaderno cambió entre corridas)
Utilizables (experimento)	11/13 = 0,85	15/18 = 0,83	12/17 = 0,71
Banco (18 preguntas)	0/15 sostenidas; fuera, se abstuvo en 2/3	12/15 sostenidas; fuera, se abstuvo en 3/3	15/15 sostenidas; fuera, se abstuvo en 2/3

Elegimos B, con la sesión abierta en `Vault_PISA2022`, el protocolo v2 y una condición: una nota del vault solo sirve de fuente si su estado es `verificado`. Es la única que exporta a APA 7, está versionada y deja rastro de la página y del estado de cada afirmación, y en el banco fue la única que se abstuvo en las tres preguntas fuera del corpus. **C** fue la más completa dentro del corpus, pero respondió con conocimiento externo una pregunta fuera de él, su cuaderno cambió entre corridas y no exporta a APA 7. **A** responde de memoria y sin páginas. La condición sale de los datos: de las notas que citó B en el experimento solo una estaba verificada, y sus fallos en el banco vinieron de notas incompletas o con errores (repitió el «solo» de la nota de Eriksson et al.).