Nada sin fuente: gestión de información e IA en el proyecto PISA 2022

Memoria — Consultoría Estadística

Vanessa Acosta, Mateo Ramos y Brayan David Barreto

Universidad Santo Tomás · 2026-II

1. Diagnóstico

Los tres inventarios (`inventarios/`) suman nueve fallos de IA. Caen en tres patrones.

La IA escribe más de lo que dice la fuente. Al redactar el estado del arte con Claude, 6 de las 16 oraciones citadas de Mateo no se sostenían completas: un «solo» que la fuente no dice, una cifra propia citada como de la OCDE, coeficientes de una asignatura presentados como del logro en general. En la matriz, Claude afirmó que el DIF por NSE «no se ha estudiado en PISA» cuando el equipo ya tenía tres fuentes que lo hacían (Vanessa). Ninguno se vio hasta abrir el PDF en la página citada.

Los procesos automáticos toman el objeto equivocado. Un script guardó como García-Medina et al. (2016) otro artículo, porque tomó el primer PDF de la página (Mateo y Brayan). Un cruce de códigos no reconoció un ítem retirado del reporte técnico porque el código cambiaba de formato (Vanessa). La comprobación en Crossref de referencias de una sola palabra devolvió registros sin relación, y llevó a marcar como inexistentes documentos que existen (Brayan).

La herramienta no usa el contexto que creemos. NotebookLM completó de memoria una cita de segundo nivel, Liu (2017), con hallazgos que el PDF no contiene (Vanessa). Una corrida de B leyó la respuesta de A fuera del vault (Mateo). B respondió con notas sin verificar y heredó sus errores (Brayan).

Los nueve se detectaron igual: abriendo el documento original. El sistema convierte eso en regla.

2. Experimento y decisión

Tres consultas bibliográficas reales, una por integrante, en tres tratamientos: A, Claude sin contexto (control); B, Claude respondiendo solo desde el vault de Obsidian; C, NotebookLM con los PDF del corpus. No hubo buscador, así que se mide anclaje, no búsqueda. Diseño, regla de conteo y desvíos en `experimento_decision.pdf`.

Cuadro 1: Experimento (proporción de referencias utilizables) y banco de evaluación (18 preguntas).

Tratamiento	Utilizables (IC 95 %)	Con las sin mayoría	Banco: sostenidas	Se abstuvo dentro	Se abstuvo fuera
A · Claude sin contexto	0,85 (0,58–0,96)	0,50 a 0,91	0/15	11	2/3
B · Zotero + Obsidian	0,83 (0,61–0,94)	0,75 a 0,85	12/15	3	3/3
C · NotebookLM	0,71 (0,47–0,87)	0,63 a 0,74	15/15	0	2/3

Ninguna diferencia del experimento es concluyente: con 13 a 18 referencias por tratamiento los intervalos se traslapan y el acuerdo entre los tres clasificadores fue bajo (kappa de Fleiss 0,062). La proporción de A sale solo de sus

referencias con mayoría; las 9 sin mayoría son de pago y, según cómo se cuenten, A va de 0,50 a 0,91. B es el más estable.

Elegimos B, con la sesión abierta en el vault, el protocolo v2 y una condición: una nota solo sirve de fuente si su estado es `verificado`. B es la única que exporta a APA 7, está versionada en Git y deja rastro de la página y del estado de cada afirmación, y fue la única que se abstuvo en las tres preguntas fuera del corpus. **Descartamos C**, la más completa dentro del corpus, porque respondió con conocimiento externo una pregunta fuera de él y su cuaderno cambió entre corridas; y **A**, porque responde de memoria y sin páginas. La condición sale de los datos: de las notas que citó B en el experimento solo una estaba verificada, y sus fallos en el banco vinieron de notas incompletas o con errores.

3. El sistema

Vía empaquetada, sin índice propio (C3 llega como máximo a *Competente*): Zotero, Obsidian y Claude, que en B responde leyendo solo el vault. NotebookLM fue la alternativa comparada.

1. **Biblioteca.** 37 fuentes en el grupo de Zotero *Proyecto Final PISA*, con la clave fija de Better BibTeX que cita el anteproyecto y su DOI o URL.
2. **Carpeta con procedencia.** Cada PDF en `corpus/{clave}.pdf`, fuera de Git; `nsf_procedencia.R` genera `README_procedencia.md` desde `procedencia.csv`. Hay 28 de 37 obtenidos; los demás son de pago o no son texto, y se declara. No hay datos de contraparte: todo el corpus es público.
3. **Tabla de trazabilidad.** Una fila por oración citada del anteproyecto (44). La pista de página no vale como verificación: firma un integrante con el documento abierto.
4. **Protocolo versionado.** La v1 fija las fuentes permitidas, la cita con página, la frase «No está en las fuentes.» y la declaración de citas indirectas. La v2 agrega la regla 6 (nada fuera del vault), después de la corrida de B que leyó la respuesta de A.
5. **Ruta de abstención,** probada con las tres preguntas del banco fuera del corpus.

Debajo está la regla: cada nota del vault tiene estado `por_verificar`, `verificado` o `sin_origen`, y la IA nunca marca `verificado`. Hoy hay 8 de 45 notas verificadas.

Cuadro 2: Estado de la tabla de trazabilidad por integrante.

persona	filas	completas	se_sostiene	parcial	no	sin_revisar
Brayan	18	17	16	1	0	1
Mateo	16	16	10	6	0	0
Vanessa	10	8	8	0	0	2
TOTAL	44	41	34	7	0	3

4. Evaluación

El banco tiene 18 preguntas, seis por integrante (cinco con respuesta en el corpus y una fuera), con la respuesta y la página anotadas antes de correrlas, y una corrida por tratamiento. Una respuesta es *sostenida* si su cita lleva a un fragmento real que lo dice; abstenerse dentro del corpus cuenta como abstención indebida (decisión D-11). Resultados en la tabla 1. A no sostuvo ninguna respuesta: se abstiene o responde de memoria, sin cita. C sostuvo todas dentro del corpus, pero respondió con conocimiento externo una de las tres de fuera. B sostuvo 12 de 15 y se abstuvo en las tres de fuera; sus fallos vinieron de las notas: se abstuvo cuando la nota no tenía el dato y repitió el «solo» de la nota de Eriksson.

Caso de fallo (`evaluacion/caso_fallo.md`). En el piloto de C, NotebookLM le atribuyó a Liu (2017), citado en Kucam y Gülleroğlu (2023) solo por un punto metodológico, hallazgos sobre NSE, género, etnia y TIMSS 2011 que el PDF no contiene. Causa: el modelo completó de memoria una cita de segundo nivel. Se detectó comparando la oración exacta en el PDF (p. 146); por este caso la regla 5 del protocolo obliga a declarar las citas indirectas.

Lo que no se hizo. No hubo auditoría cruzada con otro equipo. Cada pregunta se corrió una vez por tratamiento, y quien juzgó si se sostenía fue quien la escribió.

5. Qué corregimos de nuestro anteproyecto

Al firmar la trazabilidad, abriendo cada PDF en la página citada, estas oraciones necesitaron corrección. La página y la cita de cada una están en `trazabilidad/trazabilidad.md`.

Fila	Fuente	Cómo queda	Verificó	Resultado
T-Mat-01	OCDE (2024), reporte técnico	«la muestra principal de Colombia fue de 7 804 estudiantes», no «evaluados»	Mateo Ramos	parcial
T-Mat-04	Icfes (2019), INSE	compara los ítems entre periodos y además lo ilustra por sexo con un ítem	Mateo Ramos	parcial
T-Mat-06	Icfes (2022), marco de matemáticas	se quita «no publica resultados por competencia para cada estudiante»	Mateo Ramos	parcial
T-Mat-08	OCDE (2024), reporte técnico	las correlaciones de 0,70 a 0,83 en Colombia son cálculo propio	Mateo Ramos	parcial
T-Mat-11	Hernández y González (2011)	dos componentes bajo un factor común; el mayor peso es sobre Lenguaje	Mateo Ramos	parcial
T-Mat-12	Eriksson et al. (2021)	«superan claramente al resto», no «solo… predicen»	Mateo Ramos	parcial
T-Bra-01	Collazos et al. (2021)	«con un modelo de combinación de cortes transversales» (no nombra el estimador)	Brayan David Barreto	parcial
T-Bra-02	Zabala et al.	se corrige el año de la referencia (el documento menciona hechos de 2020)	Brayan David Barreto	sí, con ajuste
T-Van-06	Calderón et al. (2026)	«el análisis de DIF que conocemos», no «el único»	Vanessa Acosta	sí, con ajuste
T-Van-01	García-Medina et al. (2016)	«aproximadamente la mitad» de los 18 ítems	Vanessa Acosta	sí, con ajuste

Quedaron sin firmar, porque son de pago y nadie leyó el documento, Rubin (1987), Goh et al. (2024) y Pohl et al. (2014); las tres existen, se declaran aquí y sus citas no cambian. Se verificaron solo con el resumen T-Bra-09,

T-Bra-14, T-Bra-15, T-Mat-14 y T-Mat-15.

6. Declaración de uso de IA

- **Herramientas usadas:** Claude Opus 5.5 (chat y Claude Code; en la consulta de Brayan, Opus 5.5 Extra) y Claude Sonnet 5 (sesiones de Vanessa del 12 de octubre, incluido su tratamiento B); NotebookLM. Sin IA: Zotero con Better BibTeX, Obsidian, R 4.4 y las API públicas de Crossref, DataCite y OpenAlex, consultadas desde scripts.
- **Para qué las usamos:**
  - Gestión de fuentes: Claude redactó las notas del vault a partir de los PDF y propuso la página de cada cita.
  - Código del sistema: Claude Code escribió los scripts `Proyecto_PISA/scripts/nsf_*.R`.
  - Redacción: borradores de esta memoria, del documento del experimento, de los inventarios y del protocolo; cada responsable los revisó.
  - Otros: en la clasificación, scripts consultaron Crossref, DataCite y OpenAlex para la columna `evidencia`; la categoría la asignó cada integrante. El detalle por sesión está en `Vault_PISA2022/15 Bitácora de uso de IA.md`.
- **Herramienta de gestión elegida:** B (Zotero + Obsidian, con Claude leyendo solo el vault), comparada con A y C en un experimento con control y en un banco de 18 preguntas.
- **Alternativas descartadas y por qué:** C, porque respondió fuera de sus fuentes y su cuaderno cambió entre corridas; A, porque responde de memoria y sin páginas.
- **El experimento en una línea:** de las 22 referencias de A, ninguna resultó inexistente por mayoría, 2 existían pero no decían lo atribuido y 9 quedaron sin mayoría. En los tres tratamientos la mayoría marcó una sola como inexistente (Ekmekci, 2013, en B), y sí existe: su repositorio no abría y la encontramos después en OpenAlex.
- **Qué NO usamos IA para:** asignar las categorías de la clasificación, firmar filas de trazabilidad, marcar notas como `verificado`, confirmar las calificaciones del banco ni tomar las decisiones del registro.
- **Qué tuvimos que corregir de lo que generó:**
  - el enlace de García-Medina et al. (2016), que descargaba otro artículo;
  - la corrida de B que leyó la respuesta de A fuera del vault: se descartó y dio origen a la v2;
  - notas que decían «texto completo» sin que el equipo tuviera el PDF (Rutkowski y Rutkowski, Rolfe, Mittal et al.), y B lo repitió en su respuesta;
  - el «solo» de Eriksson et al., que estaba en el anteproyecto y en la nota, y que B repitió en el banco;
  - las oraciones del anteproyecto de la sección 5;
  - dos errores de los scripts (`leer_csv` duplicaba comillas; `nsf_evaluacion.R` no contaba las abstenciones de A) y dos afirmaciones de Claude sobre fuentes que resultaron falsas al abrir el PDF (que «28-30 ítems» no estaba en el reporte técnico, y que Collazos et al. «no usan MCO»).