Nada sin fuente

Gestión de información e IA en el proyecto PISA 2022 Colombia

Vanessa Acosta · Mateo Ramos · Brayan David Barreto

2026-II

Consultoría Estadística · Universidad Santo Tomás

Diagnóstico

Qué nos inventó la IA (nueve fallos en tres inventarios)

1. Escribe más de lo que dice la fuente

- 6 de las 16 oraciones citadas de Mateo no se sostenían: un «solo» que Eriksson et al. no dicen, una cifra propia citada como de la OCDE.

2. Los procesos automáticos toman el objeto equivocado

- El PDF guardado como García-Medina et al. (2016) era otro artículo; un ítem retirado no se reconoció porque su código cambiaba de formato.

3. La herramienta no usa el contexto que creemos

- NotebookLM completó de memoria Liu (2017) con hallazgos que el PDF no contiene; una corrida de B leyó la respuesta de A.

Qué costó: 7 oraciones corregidas, una corrida de B descartada y el protocolo v2.

Los nueve se detectaron igual: abriendo el documento original.

Experimento y decisión

El experimento

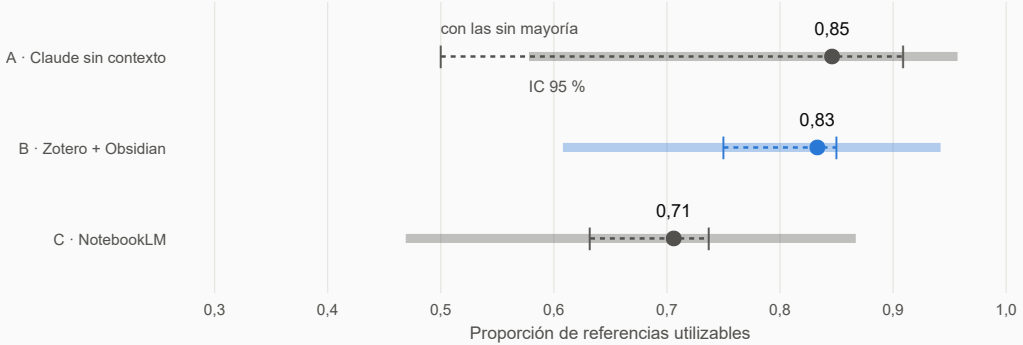
- **Tres consultas reales**, una por integrante, cada una en tres tratamientos:
  - **A** · Claude sin contexto (control)
  - **B** · Claude leyendo solo nuestro vault de Obsidian, con el protocolo v2
  - **C** · NotebookLM con los PDF del corpus
- 67 referencias; cuentan 61 (6 las nombró B solo para descartarlas).
- **Clasificación ciega por los tres**, en orden aleatorio: *utilizable* · *existe pero no dice eso* · *no existe*.
- Etiqueta final: la de la mayoría. Sin mayoría, la referencia sale del cálculo.

El conteo

Tratamiento	Utilizables	No dice eso	No existe	Sin mayoría	Proporción (IC 95 %)	Con las sin mayoría
A · Claude sin contexto	11	2	0	9	0,85 (0,58–0,96)	0,50 a 0,91
B · Zotero + Obsidian	15	2	1	2	0,83 (0,61–0,94)	0,75 a 0,85
C · NotebookLM	12	5	0	2	0,71 (0,47–0,87)	0,63 a 0,74

- Ninguna diferencia es concluyente: los intervalos se traslapan (Fisher, p = 1,00 y 0,43).
- Acuerdo entre clasificadores bajo: **kappa de Fleiss 0,062**.

Lo que el conteo no dice



- El 0,85 de A sale de 13 de sus 22 referencias: las otras 9 son de pago y quedaron sin mayoría. Según cómo se cuenten, **A va de 0,50 a 0,91**.
- **B es el más estable** (0,75 a 0,85). Con el experimento solo no se puede elegir.

Banco de evaluación: 18 preguntas con respuesta conocida

Tratamiento	Sostenidas (15 en el corpus)	Se abstuvo y estaba	Se abstuvo fuera (3)	Respondió sin fuente
A · Claude sin contexto	0/15	11	2/3	1
B · Zotero + Obsidian	12/15	3	3/3	0
C · NotebookLM	15/15	0	2/3	1

- **A** no sostiene nada con una fuente: se abstiene o responde de memoria.
- **C** sostiene las 15, pero en una pregunta trampa (Colombia en TIMSS 2019) respondió con conocimiento externo.
- **B** es la única que no se sale de sus fuentes; sus fallos vienen de las notas: una no decía «matemáticas», otra repetía el «solo» de Eriksson.

Decisión: B, con una condición

Elegimos B · Zotero + Obsidian, con Claude leyendo solo el vault y el protocolo v2

- Exporta a APA 7, está versionado en Git y deja rastro de la página y del estado de cada afirmación.
- Es la única que se abstuvo en las tres preguntas fuera del corpus.

Condición: una nota del vault solo sirve de fuente si está verificada contra el PDF.

- Sale de los datos: de las notas que citó B, solo una estaba verificada, y sus fallos vinieron de notas incompletas.

Descartadas

- **C**: se salió de sus fuentes, su cuaderno cambió entre corridas (13, 36 y 27 entradas) y no exporta referencias.
- **A**: responde de memoria y sin páginas.

El sistema

Cómo quedó montado (vía empaquetada)

Zotero · 37 fuentes con clave fija (Better BibTeX)

↓

corpus/ · PDF + `procedencia.csv` → README de procedencia

↓

Vault de Obsidian · una nota por fuente: afirmación, página y estado (`por_verificar` / `verificado`)

↓

Claude Code abierto en el vault + protocolo v2

↓

respuesta con nota, página y estado · o «No está en las fuentes.»

La IA nunca marca `verificado`: lo hace una persona con el PDF abierto.

En vivo: una consulta con su cita

1. Sesión nueva de Claude Code en `Vault_PISA2022` + protocolo v2 (menos de 60 s).
2. Avvisati y Wuyts (2024): ¿qué modelo y cambió en 2022? → nota, **p. 11** y estado → abrir el PDF.
3. Invarianza de HOMEPOS rural/urbano en Colombia → **«No está en las fuentes.»**

Si algo falla en vivo: diapositiva de respaldo «La demostración, ya corrida».

Límites

Dónde falla

- **B repite lo que digan sus notas:** hoy hay 8 de 45 notas verificadas.
- **La clasificación depende de quién clasifica:** kappa de Fleiss 0,062.
- **Lo que no pudimos leer:** Rubin (1987), Goh et al. (2024) y Pohl et al. (2014) quedaron sin firmar; cinco filas, solo con el resumen.
- **Lo que no se hizo:** auditoría cruzada con otro equipo; cada pregunta del banco se corrió una sola vez.
- **Trazabilidad:** 41 de 44 filas firmadas; 7 oraciones del anteproyecto corregidas.

Qué no le delegamos a la IA

- Firmar una fila de trazabilidad o marcar una nota como `verificado`.
- Asignar las categorías de la clasificación ciega.
- Confirmar las calificaciones del banco.
- Elegir la herramienta y tomar las decisiones del registro.

La IA propone dónde buscar; una persona abre el documento y firma.

Respaldo

La demostración, ya corrida (banco de Mateo, 2026-10-13)

Pregunta (M03): Según Avvisati y Wuyts (2024), ¿con qué modelo se construye HOMEPOS y cambió en 2022?

Respuesta de B: «HOMEPOS se construye con un modelo de TRI unidimensional, y el procedimiento no cambió en 2018 ni en 2022 (p. 11)». Fuente: `Literatura/avvisati2024measurement.md`, estado `por_verificar`.

El PDF, p. 11 (visor p. 12): «… did not change in 2018 or 2022.» La cita se sostiene.

Pregunta fuera del corpus (M06): ¿qué estudio evaluó la invarianza de HOMEPOS entre zonas rurales y urbanas de Colombia? → B: **«No está en las fuentes.»**

Respuestas completas: `evaluacion/respuestas_banco_Mateo.md`.

Qué corregimos del anteproyecto

Fila	Fuente	Cómo queda	Verificó
T-Mat-01	OCDE (2024)	«muestra principal» de 7 804, no «evaluados»	Mateo Ramos
T-Mat-04	Icfes (2019)	entre periodos y, además, por sexo con un ítem	Mateo Ramos
T-Mat-06	Icfes (2022)	se quita lo que el marco no dice	Mateo Ramos
T-Mat-08	OCDE (2024)	0,70–0,83 en Colombia es cálculo propio	Mateo Ramos
T-Mat-11	Hernández y González (2011)	dos componentes bajo un factor común	Mateo Ramos
T-Mat-12	Eriksson et al. (2021)	«superan claramente al resto», sin «solo»	Mateo Ramos
T-Bra-01	Collazos et al. (2021)	«combinación de cortes transversales» (no nombra MCO)	Brayan David Barreto
T-Bra-02	Zabala et al. (s. f.)	se corrige el año de la referencia	Brayan David Barreto
T-Van-06	Calderón et al. (2026)	«el análisis que conocemos», no «el único»	Vanessa Acosta
T-Van-01	García-Medina et al. (2016)	«aproximadamente la mitad»	Vanessa Acosta

Desvíos que declaramos

1. No hubo buscador: se midió anclaje, no búsqueda.
2. El cuaderno de NotebookLM cambió entre corridas (13, 36 y 27 entradas).
3. Una corrida de B leyó la respuesta de A: se descartó y nació la regla 6 (protocolo v2).
4. Las 6 fuentes que B nombró solo para descartarlas se sacaron después de clasificar; contándolas, B baja a 0,65.
5. Vanessa dejó sin categoría 21 referencias de pago, casi todas de A.
6. Vanessa corrió A con Opus 5.5 y B con Sonnet 5; Mateo y Brayan, el mismo modelo en los dos.