Nada sin fuente

Gestión de información e IA en el proyecto PISA 2022 Colombia

Vanessa Acosta · Mateo Ramos · Brayan David Barreto

2026-II

Consultoría Estadística · Universidad Santo Tomás

El proyecto

Nuestro proyecto: nivel socioeconómico y matemáticas en PISA 2022

La pregunta. ¿En qué medida el NSE, medido como **constructo latente** que mide lo mismo entre grupos, explica el desempeño de los estudiantes colombianos en cada una de las **cuatro competencias matemáticas** de PISA 2022?

Los datos. Base pública de PISA 2022 (OCDE): 7 804 estudiantes de 15 años y 262 colegios de Colombia; 234 ítems de matemáticas en un diseño adaptativo multietapa.

Por qué importa. El NSE explica el 16 % de la variación en matemáticas (25 puntos), más que en la OCDE (15 %) y en Latinoamérica (13 %). Pero esa brecha depende de **dos decisiones de medición**: cómo se mide el NSE y cómo se califica el desempeño.

Objetivos

1. **NSE latente** con TRI y análisis factorial (una o dos dimensiones).
2. **Invarianza** del NSE por zona, sexo y sector (configural, métrica, escalar).
3. **Calificación por competencia** con TRI multidimensional, DIF por NSE y omisiones.
4. **Modelo estructural**: efecto del NSE en cada competencia, con pesos y valores plausibles.
5. **API y tablero** con los resultados agregados.

Todo se apoya en un **estado del arte de 37 fuentes**.

Por qué «Nada sin fuente»

El agente y el anteproyecto se construyeron con ayuda de IA, y el resto del semestre seguiremos usándola. La actividad pide **un sistema que haga rastreable todo lo que entra al proyecto**: dónde viven las fuentes, qué se le permite responder al modelo, qué responde cuando no sabe y cómo se comprueba.

Qué inventa el modelo	Es un problema de	Se resuelve con
Referencias que no existen, o que no dicen lo atribuido	**búsqueda**	buscar en bases bibliográficas reales y abrir cada referencia
Afirmaciones falsas sobre documentos que ya tenemos	**anclaje**	contexto cerrado con cita obligatoria
Cálculos que suenan bien y están mal	**cálculo**	que el modelo ejecute código y se valide la salida

Nuestro foco: el anclaje sobre las fuentes del anteproyecto. La prueba final: el profesor señala una frase del anteproyecto y mostramos de dónde sale.

Diagnóstico

Qué nos inventó la IA: nueve fallos en tres patrones

1. Escribe más de lo que dice la fuente

- En una sección del estado del arte, 6 de 16 oraciones citadas no se sostenían: un «solo» que Eriksson et al. no dicen, una cifra propia citada como de la OCDE.
- La matriz del estado del arte afirmaba que el DIF por NSE «no se ha estudiado en PISA», y ya teníamos tres fuentes que lo hacían.

2. Los procesos automáticos toman el objeto equivocado

- El PDF guardado como García-Medina et al. (2016) era otro artículo; un ítem retirado no se reconoció porque su código cambiaba de formato; Crossref devolvió registros sin relación.

3. La herramienta no usa el contexto que creemos

- NotebookLM completó de memoria una cita; una corrida de B leyó la respuesta de A; B respondió con notas sin verificar.

Qué costó: 7 oraciones del anteproyecto corregidas, una corrida descartada y el protocolo v2. Los nueve se detectaron igual: abriendo el documento original.

El caso de fallo: una cita de segundo nivel

- **Pregunta (piloto de C, NotebookLM):** ¿qué estudios usan DIF por NSE en las competencias matemáticas de PISA?
- **Lo que respondió:** que Liu (2017) analizó el DIF por nivel socioeconómico, género, etnia y lengua materna en TIMSS 2011.
- **Lo que dice el PDF:** Kucam y Gülleroğlu (2023) citan a Liu (2017) solo por un punto metodológico, en la p. 146: qué método detecta más DIF. Liu (2017) es una tesis que compara métodos de detección.
- **Causa:** el modelo describió bien el artículo cargado, pero **completó de memoria** la referencia que ese artículo cita (una cita de segundo nivel).
- **Cómo se detectó:** abriendo el PDF y buscando «Liu 2017» para comparar la oración exacta.

Qué cambió: la regla 5 del protocolo obliga a declarar toda cita indirecta como no verificada.

Experimento y decisión

El experimento: ¿qué herramienta inventa menos?

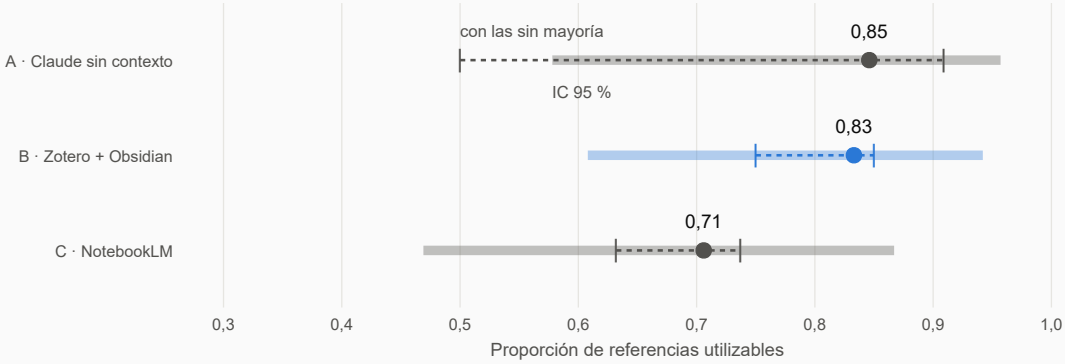
- **Tres consultas bibliográficas reales** del proyecto, una por integrante (invarianza del NSE, DIF por NSE, SEM con valores plausibles), cada una en tres tratamientos:
  - **A** · Claude sin contexto ni búsqueda web (control)
  - **B** · Claude leyendo solo nuestro vault de Obsidian, con el protocolo de consulta
  - **C** · NotebookLM con los PDF del corpus
- 67 referencias; cuentan 61 (6 las nombró B solo para descartarlas).
- **Clasificación ciega por los tres**, sin ver el tratamiento y en orden aleatorio: *utilizable* · *existe pero no dice eso* · *no existe*. Etiqueta final: la de la mayoría.

El conteo

Tratamiento	Utilizables	No dice eso	No existe	Sin mayoría	Proporción (IC 95 %)	Con las sin mayoría
A · Claude sin contexto	11	2	0	9	0,85 (0,58–0,96)	0,50 a 0,91
B · Zotero + Obsidian	15	2	1	2	0,83 (0,61–0,94)	0,75 a 0,85
C · NotebookLM	12	5	0	2	0,71 (0,47–0,87)	0,63 a 0,74

- Ninguna diferencia es concluyente: B − A = -0,01 (p = 1,00) y C − A = -0,14 (p = 0,43), con intervalos que incluyen el cero.
- Las referencias de una misma consulta no son independientes: el número efectivo está más cerca de tres consultas por tratamiento.

Lo que el conteo no dice



- El 0,85 de A sale de 13 de sus 22 referencias: las otras 9 son de pago y quedaron sin mayoría. Según cómo se cuenten, **A va de 0,50 a 0,91**.
- **B es el más estable** (0,75 a 0,85). Con el experimento solo no se puede elegir.

¿Cuánto coincidimos al clasificar?

- De 40 referencias que clasificamos los tres, hubo desacuerdo en 23 (acuerdo total 42,5 %).
- **Kappa de Fleiss = 0,062**: apenas mejor que el azar. Kappa de Cohen por pares: 0,23 · 0,15 · -0,04.
- Casi todo el desacuerdo está en una frontera: **¿la fuente dice lo que se le atribuye, o solo algo parecido?** («utilizable» frente a «existe pero no dice eso»). Pocas veces se discutió si la referencia existe.
- Un clasificador dejó sin categoría las referencias que no pudo abrir (de pago); los otros dos las clasificaron con el resumen.

Consecuencia: las proporciones dependen de quién clasifica. La decisión necesita otra medida.

Banco de evaluación: 18 preguntas con respuesta conocida

Tratamiento	Sostenidas (15 en el corpus)	Se abstuvo y estaba	Se abstuvo fuera (3)	Respondió sin fuente
A · Claude sin contexto	0/15	11	2/3	1
B · Zotero + Obsidian	12/15	3	3/3	0
C · NotebookLM	15/15	0	2/3	1

- Seis preguntas por integrante sobre sus propias fuentes: cinco con respuesta y página conocidas en el corpus, una fuera.
- **A** no sostiene nada con una fuente: se abstiene o responde de memoria.
- **C** sostiene las 15, pero en una pregunta trampa (Colombia en TIMSS 2019) respondió con conocimiento externo.
- **B** es la única que no se sale de sus fuentes; sus fallos vienen de las notas: una no decía «matemáticas», otra repetía el «solo» de Eriksson.

Decisión: B, con una condición

Criterio	A · Claude sin contexto	B · Zotero + Obsidian	C · NotebookLM
Contexto cerrado	No	**Sí (vault, protocolo v2)**	Sí (cuaderno)
Cita con página	No (solo DOI)	**Sí, con su estado**	Sí, variable
Exporta a APA 7	No	**Sí (Zotero + Better BibTeX)**	No
Versionado y reproducible	No	**Sí (Git)**	No (cambió entre corridas)
Privacidad	La pregunta va a Anthropic	**Notas a Anthropic; PDF locales**	Los PDF van a Google
Experimento: utilizables	0,85 (0,50 a 0,91)	**0,83 (0,75 a 0,85)**	0,71 (0,63 a 0,74)
Banco: sostenidas	0/15	**12/15**	15/15
Fuera del corpus: se abstuvo	2/3	**3/3**	2/3

Elegimos B, con una condición: una nota del vault solo sirve de fuente si está verificada contra el PDF. Sale de los datos: de las notas que citó B, solo una estaba verificada, y sus fallos vinieron de notas incompletas. **C** se salió de sus fuentes y su cuaderno cambió entre corridas; **A** responde de memoria y sin páginas.

El sistema

Cómo quedó montado (vía empaquetada)

Zotero · 37 fuentes del estado del arte, con clave fija (Better BibTeX) y DOI o URL

↓

corpus/ · 28 PDF obtenidos + `procedencia.csv` → README de procedencia

↓

Vault de Obsidian · una nota por fuente: afirmación, página, cita corta y estado

↓

Claude Code abierto solo en el vault + protocolo de consulta v2

↓

respuesta con nota, página y estado · o «No está en las fuentes.»

Por qué empaquetada: sin índice propio (C3 llega a *Competente*); preferimos dedicar el tiempo a verificar fuentes y a medir. **Datos de contraparte:** ninguno; todo el corpus es público.

El protocolo de consulta

Lo que se le pega a Claude antes de cada pregunta (v2):

1. Responde solo con lo que está **literalmente** en las fuentes; nada de conocimiento general.
2. Cada afirmación con **documento y página** (o sección).
3. Si la fuente es solo un resumen, dilo.
4. Si no está en las fuentes, responde exactamente **«No está en las fuentes.»**
5. Si citas una referencia mencionada dentro de otra, decláralo como **cita indirecta** no verificada.
6. **No abras nada fuera del vault** ni busques en internet.

- La v1 se congeló al inicio y no se borra. La **v2** agregó la regla 6 cuando una corrida de B leyó la respuesta de A.
- Cada nota del vault tiene estado `por_verificar`, `verificado` o `sin_origen`. **Hoy: 8 de 45 verificadas.**

Trazabilidad: de la frase del anteproyecto al PDF

Una fila por cada oración citada del anteproyecto (44 filas). Ejemplo:

Campo	Contenido
Oración	«La prueba usó un diseño adaptativo multietapa con 234 ítems, de los que cada estudiante respondió entre 28 y 30…»
Fuente	OCDE (2024), *PISA 2022 Technical Report*
Ubicación	p. 35 del PDF: «234 mathematics items from a total of 99 units», «ranged from 28-30»
¿Se sostiene?	sí
Verificó	un integrante, con el PDF abierto (nombre y fecha en la tabla)

- **41 de 44 filas firmadas**; 7 oraciones se sostenían solo en parte y se corrigieron.
- La pista automática de esta fila decía que «28 a 30» no aparecía, y sí aparece: **la pista no es evidencia**.

En vivo: una consulta con su cita

1. Sesión nueva de Claude Code en `Vault_PISA2022` + protocolo v2 (menos de 60 s).
2. Avvisati y Wuyts (2024): ¿qué modelo y cambió en 2022? → nota, **p. 11** y estado → abrir el PDF.
3. Invarianza de HOMEPOS rural/urbano en Colombia → **«No está en las fuentes.»**

Si algo falla en vivo: diapositiva de respaldo «La demostración, ya corrida».

Límites

Qué corregimos del anteproyecto

Fuente	Decíamos	Queda
OCDE (2024)	7 804 estudiantes «evaluados»	«la muestra principal» fue de 7 804
Icfes (2019), INSE	el DIF se evalúa solo entre periodos	entre periodos y, además, por sexo con un ítem
Icfes (2022), marco	no publica resultados por competencia	se quita: el marco no lo dice
OCDE (2024)	correlaciones de 0,70 a 0,83 en Colombia	son cálculo propio, no de la OCDE
Hernández y González (2011)	dos factores correlacionados	dos componentes bajo un factor común
Eriksson et al. (2021)	«solo» dos componentes predicen	«superan claramente al resto»
Collazos et al. (2021)	«con mínimos cuadrados ordinarios»	«con un modelo de combinación de cortes transversales»
Zabala et al.	año 2019	(s. f.): el documento no tiene fecha
Calderón et al. (2026)	«el único» análisis de DIF nacional	«el análisis que conocemos»
García-Medina et al. (2016)	la mitad de los ítems	«aproximadamente la mitad»

Dónde falla

- **B repite lo que digan sus notas:** hoy hay 8 de 45 notas verificadas.
- **La clasificación depende de quién clasifica:** kappa de Fleiss 0,062.
- **No medimos búsqueda:** no hubo tratamiento de buscador bibliográfico; el experimento mide anclaje.
- **Lo que no pudimos leer:** Rubin (1987), Goh et al. (2024) y Pohl et al. (2014) quedaron sin firmar (de pago); cinco filas, solo con el resumen.
- **Lo que no se hizo:** auditoría cruzada con otro equipo; cada pregunta del banco se corrió una sola vez.

Qué no le delegamos a la IA, y qué sigue

No le delegamos:

- Firmar una fila de trazabilidad o marcar una nota como `verificado`.
- Asignar las categorías de la clasificación ciega y confirmar las calificaciones del banco.
- Elegir la herramienta y tomar las decisiones del proyecto.

Qué sigue para el proyecto PISA:

- Verificar las notas que usarán los objetivos 1 a 5 antes de citarlas.
- Consultar las fuentes nuevas con el sistema: protocolo v2, cita con página y trazabilidad desde el inicio.

La IA propone dónde buscar; una persona abre el documento y firma.

Respaldo

La demostración, ya corrida (banco de evaluación, 2026-10-13)

Pregunta del banco: Según Avvisati y Wuyts (2024), ¿con qué modelo se construye HOMEPOS y cambió en 2022?

Respuesta de B: «HOMEPOS se construye con un modelo de TRI unidimensional, y el procedimiento no cambió en 2018 ni en 2022 (p. 11)». Fuente: `Literatura/avvisati2024measurement.md`, estado `por_verificar`.

El PDF, p. 11 (visor p. 12): «… did not change in 2018 or 2022.» La cita se sostiene.

Pregunta fuera del corpus: ¿qué estudio evaluó la invarianza de HOMEPOS entre zonas rurales y urbanas de Colombia? → B: **«No está en las fuentes.»**

La estadística del experimento

- **Intervalo de Wilson** para cada proporción: con pocas referencias y proporciones cerca de 1, el de Wald falla (15/15 daría [1; 1]); Wilson da 0,80–1,00.
- **Diferencia frente a A con el método de Newcombe**, que combina los intervalos de Wilson; **prueba exacta de Fisher** para la tabla 2×2, porque los conteos son pequeños.
- **Kappa** = (acuerdo observado − acuerdo por azar) / (1 − acuerdo por azar). Cohen para pares; Fleiss para los tres. Por debajo de 0,20 es un acuerdo leve.
- **Sin mayoría:** se excluyen del cálculo; como se concentran en A, se reporta el rango entre contarlas todas como no utilizables y todas como utilizables.
- **No independencia:** las referencias de una consulta comparten respuesta y tema; los intervalos se leen como orientativos.

Desvíos que declaramos

1. No hubo buscador: se midió anclaje, no búsqueda.
2. El cuaderno de NotebookLM cambió entre corridas (13, 36 y 27 entradas); una C con el cuaderno incompleto se repitió.
3. Una corrida de B leyó la respuesta de A: se descartó y nació la regla 6 (protocolo v2).
4. Las 6 fuentes que B nombró solo para descartarlas se sacaron después de clasificar; contándolas, B baja a 0,65.
5. Un clasificador dejó sin categoría 21 referencias de pago, casi todas de A; en ellas cuenta la etiqueta solo si los otros dos coinciden.
6. En una de las tres consultas, A y B se corrieron con modelos distintos (Opus 5.5 y Sonnet 5).
7. La única referencia que la mayoría marcó «no existe» (Ekmekci, 2013) sí existe: su repositorio no abría.